

Modelado Predictivo de la Oferta de Producción de Aguacate en el Estado de Jalisco

Carolina Lucas Dophe
Maestría en Inteligencia Artificial Aplicada
Tecnológico de Monterrey
Querétaro, México
A01702450

Juan Pablo López Sánchez
Maestría en Inteligencia Artificial Aplicada
Tecnológico de Monterrey
Zapopan, México
A01313663

Víctor Hugo Soto Herrera
Maestría en Inteligencia Artificial Aplicada
Tecnológico de Monterrey
Querétaro, México
A01706446

Resumen— Este trabajo presenta el desarrollo y evaluación de modelos de aprendizaje automático para el modelado predictivo de la oferta de producción de aguacate en el estado de Jalisco, con el objetivo de explorar herramientas analíticas que puedan apoyar la toma de decisiones estratégicas de la Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL). A partir de datos históricos de producción, se construyó un conjunto de modelos predictivos que incluyen enfoques estadísticos, de aprendizaje automático y modelos de ensamble.

Se evaluaron múltiples algoritmos mediante métricas estándar de predicción, tales como MAE, RMSE, MAPE, MASE y R^2 . Posteriormente, se implementaron distintos métodos de ensamble con el fin de mejorar el desempeño predictivo. El modelo seleccionado fue un Stacking Ensemble con Random Forest como metamodelo, el cual mostró el mejor equilibrio entre exactitud y estabilidad en comparación con los modelos base.

Los resultados muestran que el modelo es capaz de capturar adecuadamente las tendencias generales de la serie temporal, aunque presenta limitaciones para predecir eventos extraordinarios o cambios abruptos en la producción. Finalmente, se discute la viabilidad de su implementación como herramienta de apoyo analítico, así como recomendaciones para su mejora futura mediante la incorporación de variables exógenas y estrategias de monitoreo y mantenimiento del modelo.

Palabras clave: series de tiempo, aprendizaje automático, ensamble de modelos, stacking, predicción agrícola, producción de aguacate, análisis predictivo.

I. INTRODUCCIÓN

El aguacate es uno de los productos agrícolas de mayor relevancia económica para México, particularmente en estados con alta vocación productiva como Jalisco. La creciente demanda nacional e internacional ha incrementado la necesidad de contar con herramientas analíticas que permitan anticipar tendencias de producción y apoyar la planificación estratégica del sector. En este contexto, la generación de modelos predictivos basados en datos históricos puede aportar información valiosa para la toma de decisiones.

La Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL) agrupa a diversos productores y actores clave de la cadena de valor del aguacate en la región. Para este tipo de organizaciones, contar con estimaciones razonables de la oferta futura puede contribuir a mejorar la planificación de exportaciones, logística, almacenamiento y estrategias comerciales, especialmente en un mercado caracterizado por fluctuaciones de demanda y factores externos que influyen en la producción.

En los últimos años, los métodos de aprendizaje automático y modelado de series temporales han demostrado ser herramientas eficaces para analizar fenómenos complejos y generar predicciones basadas en patrones históricos. En particular, los enfoques de ensamble de modelos permiten combinar diferentes algoritmos con el objetivo de mejorar la precisión y robustez de las predicciones frente a la variabilidad inherente de los datos.

El presente trabajo desarrolla y compara diversos modelos predictivos aplicados a una serie temporal de producción de aguacate, con el objetivo de identificar el enfoque con mejor desempeño. Además de evaluar métricas cuantitativas, se realiza un análisis visual del comportamiento del modelo seleccionado y se discuten sus limitaciones, así como su posible integración dentro de un entorno de producción que permita su uso como herramienta de apoyo para la toma de decisiones.

II. METODOLOGÍA – RESUMEN DEL MODELADO

La metodología empleada en este proyecto se basó en un enfoque de modelado predictivo supervisado aplicado a series temporales y variables agro-productivas, con el objetivo de estimar la oferta de producción de aguacate en el estado de Jalisco. El proceso siguió un flujo estructurado que incluyó la preparación de datos, el entrenamiento de múltiples modelos de aprendizaje automático y la evaluación comparativa de su desempeño.

En primer lugar, se realizó la integración y limpieza de los datos provenientes de distintas fuentes relacionadas con producción agrícola, superficie cultivada y otras variables relevantes para el cultivo de aguacate en la región. Posteriormente se aplicaron técnicas de preprocesamiento y

transformación de variables, incluyendo manejo de valores faltantes, generación de variables derivadas y estandarización cuando fue necesario.

Una vez preparado el conjunto de datos, se procedió al entrenamiento de diversos modelos de aprendizaje automático, con el objetivo de comparar su capacidad predictiva. Este enfoque de evaluación comparativa permite identificar el algoritmo que mejor se ajusta a los patrones presentes en los datos. En el ámbito del aprendizaje automático, es común evaluar múltiples modelos para seleccionar aquel que presenta el mejor equilibrio entre exactitud y capacidad de generalización.

Finalmente, los modelos fueron evaluados utilizando métricas de desempeño apropiadas para problemas de regresión, como error absoluto medio escalado (MASE), error absoluto medio (MAE), error de porcentaje medio absoluto (MAPE), error cuadrático medio (RMSE) y coeficiente de determinación (R^2). Con base en estas métricas se realizó un análisis comparativo que permitió seleccionar el modelo con mejor desempeño predictivo para su uso en el sistema propuesto.




Fig. 1. Flujo de la Metodología

III. RESULTADOS DEL MODELADO

Esta sección presenta los resultados obtenidos durante la fase de modelado predictivo. Con el objetivo de identificar el algoritmo con mejor capacidad de predicción, se entrenaron y evaluaron distintos modelos de aprendizaje automático utilizando el mismo conjunto de datos y el mismo esquema de evaluación, aplicando técnicas y configuraciones específicas acorde a la naturaleza de cada modelo, garantizando en cada momento el respeto a la cronología de los datos durante el entrenamiento y validación.

El desempeño de cada modelo fue evaluado mediante métricas cuantitativas que permiten medir la diferencia entre los valores reales observados y las predicciones generadas por el modelo. Este enfoque permite comparar de manera objetiva distintos algoritmos y seleccionar aquel que ofrece mejores resultados en términos de precisión y estabilidad.

Además de las métricas numéricas, se analizaron las predicciones generadas por cada modelo con el fin de evaluar su comportamiento frente a las tendencias presentes en los datos históricos de producción. Este análisis permitió identificar qué

modelos capturan de manera más adecuada la dinámica de la producción agrícola.




Fig. 2. Comparación: Predicciones (Top-3) vs. Valores Reales

A. Comparación de Modelos

Con el propósito de identificar el modelo más adecuado para la predicción de la oferta de producción de aguacate, se entrenaron múltiples algoritmos de aprendizaje automático y se evaluó su desempeño utilizando un mismo conjunto de validación, respetando en todo momento la cronología de los datos.

Los resultados obtenidos muestran diferencias en el desempeño de los distintos modelos evaluados. Algunos modelos presentan menor error promedio en las predicciones, mientras que otros muestran mayor estabilidad en su capacidad de generalización. Este análisis comparativo permite identificar las fortalezas y limitaciones de cada enfoque de modelado.

A partir de estos resultados se realizó una comparación sistemática de los modelos entrenados, considerando tanto el desempeño predictivo como la consistencia de los resultados obtenidos durante el proceso de validación.

Modelo	MASE	RMSE	MAE	MAPE	R ²	Tiempo
Stacking RF	0.485	0.056	0.042	6.293	0.686	56.529
Stacking Ridge	0.493	0.056	0.043	6.411	0.677	1.151
GPR	0.493	0.056	0.043	6.411	0.677	10.788
Weighted Average Ensemble	0.508	0.057	0.044	6.588	0.663	0.001
Bagging GPR	0.521	0.059	0.045	6.788	0.641	96.879
Simple Average Ensemble	0.540	0.061	0.047	6.984	0.623	0.001
SARIMAX	0.577	0.063	0.050	7.411	0.589	21.287
Prophet	0.582	0.066	0.050	7.632	0.557	0.508
MLP-100x100-relu-a0.0001-lr0.01	0.599	0.065	0.051	7.502	0.562	0.265
SVR	0.642	0.067	0.056	8.100	0.541	0.012
LSTM	0.924	0.096	0.080	12.597	0.021	5.490
Auto-ARIMA	0.946	0.104	0.082	12.786	-0.106	108.205
ARIMA	1.064	0.114	0.092	13.198	-0.320	108.205
Exponential Smoothing	1.085	0.123	0.094	14.071	-0.549	0.013

Fig. 3. Comparativa de Métricas

B. Selección del Modelo Final

A partir de los resultados obtenidos en la comparación de modelos, se procedió a seleccionar el modelo con mejor desempeño predictivo para su utilización en el sistema propuesto, resultando ser el modelo de ensamble *Stacking Random Forest*. La selección se realizó considerando principalmente las métricas de error obtenidas en el conjunto de validación, así como la capacidad del modelo para capturar adecuadamente las tendencias observadas en los datos.

El modelo final seleccionado no solo logró reducir el error promedio en comparación con los demás modelos evaluados, sino que también mostró un comportamiento consistente frente a distintos subconjuntos de los datos.

La elección de un modelo final basado en un proceso sistemático de comparación permite aumentar la confiabilidad del sistema predictivo. En aplicaciones prácticas, como la planificación de producción agrícola, contar con un modelo robusto y válido es fundamental para apoyar la toma de decisiones informadas.

El modelo *Stacking Random Forest* constituye la base del sistema de predicción propuesto para estimar la oferta de producción de aguacate en el estado de Jalisco, el cual puede integrarse posteriormente en una infraestructura de despliegue y consumo mediante servicios de predicción.




Fig. 4. Comparación: Predicciones (Stacking RF) vs. Valores Reales

IV. ANÁLISIS DEL DESEMPEÑO DEL MODELO

Una vez seleccionado el modelo final con base en su desempeño comparativo frente a los modelos base y de ensamble, se realizó un análisis detallado de su comportamiento con el fin de evaluar su capacidad predictiva, estabilidad y confiabilidad. Este análisis permite entender no solo el nivel de error del modelo, sino también identificar posibles patrones sistemáticos en las predicciones, evaluar la independencia de los residuos y analizar la contribución relativa de los modelos y variables utilizadas.

En esta sección se presentan distintos análisis visuales y métricos que permiten evaluar la calidad del modelo desde múltiples perspectivas: comportamiento de las predicciones en el tiempo, distribución y autocorrelación de los residuos, importancia relativa de los modelos dentro del ensamble y análisis cuantitativo de los errores obtenidos.

A. Comportamiento de las Predicciones en el Tiempo

Una de las formas más directas de evaluar el desempeño de un modelo de series temporales consiste en comparar visualmente las predicciones generadas por el modelo con los valores observados en la serie real. Este análisis permite identificar si el modelo es capaz de capturar adecuadamente la tendencia general, la estacionalidad y las variaciones presentes en los datos.

En los resultados obtenidos, el modelo final muestra una capacidad consistente para seguir la dinámica general de la serie temporal de producción de aguacate. Las predicciones generadas reproducen de manera adecuada los ciclos estacionales presentes en los datos, así como las fluctuaciones de mediano plazo observadas en la producción. En particular, el modelo logra mantener una cercanía razonable con los valores reales durante la mayor parte del periodo evaluado.

No obstante, como es común en problemas de predicción de series económicas o agrícolas, se observan desviaciones en algunos puntos donde se presentan cambios abruptos o variaciones atípicas en la producción. Estas diferencias reflejan la dificultad inherente de anticipar eventos no recurrentes o perturbaciones externas que no se encuentran explícitamente representadas en las variables utilizadas por el modelo.

En general, el análisis visual sugiere que el modelo logra capturar adecuadamente los patrones principales de la serie temporal, lo que respalda su utilidad como herramienta de apoyo para la estimación futura de la oferta de producción.




Fig. 5. Comparación: Predicciones (Stacking RF) vs. Valores Reales

B. Análisis de Residuos

El análisis de residuos permite evaluar si los errores del modelo presentan patrones sistemáticos o si, por el contrario, se comportan de manera aleatoria. Idealmente, un modelo bien ajustado produce residuos centrados alrededor de cero y sin estructura observable.

En el modelo seleccionado, los residuos presentan una distribución centrada en valores cercanos a cero, lo cual indica que el modelo no presenta un sesgo sistemático hacia la sobreestimación o subestimación de la producción. La magnitud de los residuos observados se mantiene relativamente acotada a lo largo del periodo analizado, lo que sugiere un comportamiento estable del modelo frente a distintas condiciones de la serie temporal.

El análisis visual de la dispersión de los residuos tampoco revela patrones claros asociados al tiempo o al nivel de la variable objetivo, lo cual es consistente con el supuesto de que los errores se comportan de forma aproximadamente aleatoria. Esta característica es deseable, ya que indica que el modelo ha capturado la mayor parte de la información estructural presente en los datos.

No obstante, se observan algunos residuos de mayor magnitud en puntos específicos de la serie, los cuales pueden estar asociados a eventos atípicos o a variaciones inesperadas en la producción. Este comportamiento es común en modelos aplicados a datos reales, especialmente en contextos agrícolas donde factores climáticos, logísticos o de mercado pueden influir en la producción.




Fig. 6. Serie Temporal de Residuos




Fig. 7. Distribución de Residuos

C. Autocorrelación de Residuos

Un aspecto fundamental en la evaluación de modelos de series temporales es verificar si los residuos presentan autocorrelación. Si los errores están correlacionados entre sí, esto sugiere que el modelo no ha capturado completamente la estructura temporal de los datos.

Para evaluar este comportamiento se analizó la función de autocorrelación de los residuos. Idealmente, los coeficientes de autocorrelación deberían encontrarse dentro de los límites de confianza, lo que indicaría que no existe dependencia significativa entre los errores en distintos rezagos.

Los resultados obtenidos muestran que la mayoría de los coeficientes de autocorrelación se encuentran dentro de los intervalos de confianza estadística, lo que sugiere que el modelo logra capturar adecuadamente la estructura temporal principal de la serie. La ausencia de autocorrelación significativa en los residuos indica que los errores del modelo se comportan de manera aproximadamente independiente.

Este resultado refuerza la validez del modelo desde el punto de vista estadístico, ya que sugiere que no existen patrones temporales importantes que el modelo haya dejado sin explicar.




Fig. 8. Autocorrelación de Residuos

D. Importancia de Modelos y Variables

Dado que el modelo final se basa en un enfoque de ensemble, resulta relevante analizar la contribución relativa de los distintos modelos base que lo componen. Este análisis permite identificar cuáles modelos aportan mayor información predictiva dentro del sistema combinado.

Los resultados indican que algunos modelos presentan una mayor influencia en la generación de las predicciones finales, mientras que otros contribuyen en menor medida o principalmente en situaciones específicas de la serie temporal. Esta diversidad de contribuciones es una de las principales ventajas de los enfoques de ensemble, ya que permite combinar distintos enfoques de modelado para capturar patrones complementarios en los datos.

Además del análisis de la contribución de los modelos, también se puede evaluar la relevancia de las variables utilizadas por los modelos que incorporan información exógena. Este análisis permite identificar cuáles variables tienen mayor impacto en la capacidad predictiva del sistema.

En conjunto, el análisis de importancia proporciona información útil para entender el comportamiento interno del modelo y orientar posibles mejoras futuras, como la incorporación de nuevas variables explicativas o la optimización de los pesos utilizados en el ensemble.




Fig. 9. Importancia de Modelos y Variables

E. Evaluación de Errores

Para complementar el análisis visual del desempeño del modelo, se evaluaron diversas métricas cuantitativas de error comúnmente utilizadas en problemas de predicción. Estas métricas permiten medir la precisión del modelo desde distintas perspectivas y facilitar la comparación con modelos alternativos.

Entre las métricas utilizadas se encuentran el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE), el Error Porcentual Absoluto Medio (MAPE), el coeficiente de determinación (R^2) y el Error Absoluto Escalado Medio (MASE). Cada una de estas métricas captura diferentes aspectos del desempeño del modelo, como la magnitud promedio de los errores, la penalización de errores grandes o la proporción de variabilidad explicada por el modelo.

Los resultados obtenidos muestran que el modelo seleccionado presenta un desempeño competitivo en comparación con los modelos base evaluados durante el proceso de modelado. En particular, las métricas de error indican que el modelo logra reducir significativamente los errores en relación con los enfoques más simples, como el modelo *Exponential Smoothing*.

Este comportamiento sugiere que el modelo final es capaz de capturar patrones relevantes en la serie temporal de producción de aguacate, proporcionando predicciones con un nivel de precisión adecuado para aplicaciones analíticas y de planeación.

V. DISCUSIÓN DE RESULTADOS

Como se puede demostrar en la comparación de los resultados obtenidos de todos los modelos, el modelo final seleccionado *Stacking Random Forest* es el que mejor rendimiento presenta, pero esta comparación por sí sola no garantiza que el modelo vaya a ser confiable en el entorno de producción. Por ello, en esta sección se analiza el modelo final junto con los objetivos y necesidades del negocio para decidir si el modelo cumple con los criterios de éxito definidos que garanticen su utilidad.

A. Calidad del Modelo

Si bien no existe un valor universal para las métricas que se emplearon en este proyecto para indicar que el modelo se encuentra listo en producción, sí existen diversas herramientas que en conjunto permiten tener un entendimiento global del rendimiento del modelo para poder decidir si será de utilidad en el entorno de producción.

La primera herramienta es el análisis del cumplimiento de los criterios de éxito definidos en la Fase 0 del proyecto. En esa fase se estableció como meta principal superar al modelo baseline *Exponential Smoothing*, el modelo más simple, ya que un modelo se considera útil cuando es significativamente mejor que un modelo simple. La métrica MASE obtenida para el modelo final es la que ayuda directamente a comparar el rendimiento de este modelo contra el baseline. El modelo final obtuvo en esta métrica un valor de 0.48, indicando entonces que el error del modelo final es 52% menor que el del baseline. Esta cantidad es significativa porque demuestra que la complejidad del modelo final sí aporta valor para realizar predicciones más confiables. Además de que se demuestra que el modelo final ha logrado cumplir el criterio de éxito establecido al inicio de este proyecto.

La herramienta anterior por sí sola puede llegar a sesgar, ya que el modelo final sí es mejor que el modelo más simple, pero puede suceder que el modelo final todavía necesite mayor robustez. Para descartar este caso, otra herramienta importante para complementar este análisis es la evaluación de las métricas del modelo que lo comparan directamente con los datos reales.

Para este análisis es importante considerar métricas que vayan acorde según las características del modelo y del problema. Como se está trabajando con un problema de series de tiempo y que los objetivos del negocio están orientados a estimar el volumen de producción, entonces una métrica importante que se puede emplear es RMSE, porque como penaliza significativamente los errores grandes cometidos por el modelo, entonces permite evaluar la robustez para evitar que se cometan errores costosos para el negocio. En la Figura 3, se puede ver que el modelo final seleccionado es el que tiene el menor RMSE, teniendo un error típico de aproximadamente 0.05 en la escala normalizada de volumen de producción de aguacate.

Otra métrica muy importante por evaluar conforme al contexto del problema es MAE, debido a que facilita la interpretación de los resultados del modelo y evalúa su desempeño de manera intuitiva empleando las unidades de la variable objetivo. En la Figura 3, nuevamente se puede observar que el modelo final es el que tiene el menor MAE, donde en promedio el modelo se equivoca 0.04 unidades en la escala normalizada del volumen de producción de aguacate, es decir un 4% del rango total. Como la métrica obtenida de RMSE es muy similar a la de MAE, entonces se puede saber que los errores del modelo son bastante consistentes y no hay errores grandes ocasionales.

Adicionalmente, otra métrica que se empleó fue MAPE, sin embargo, debido a que los datos se encuentran normalizados, fue necesario excluir aquellos registros cuyo valor era igual a cero para evitar que el cálculo se invalidara. Como consecuencia, el

resultado de esta métrica puede distorsionar la interpretación real del desempeño del modelo en este contexto, aunque sigue siendo útil como referencia complementaria. En la Figura 3 se observa que el modelo final presenta el valor más bajo de MAPE, lo que sugiere de manera sesgada que, en promedio, el modelo presenta un error aproximado del 6.29% con respecto al valor real de producción.

Finalmente, también se consideró la métrica R^2 . Aunque esta métrica no es la más adecuada para modelos de series de tiempo, ya que pierde interpretabilidad al comparar el modelo con una predicción basada en una medida global, puede utilizarse como criterio para descartar modelos. Como se aprecia en la Figura 3, en esta ocasión el modelo final no presenta el valor más bajo de R^2 ; sin embargo, esto no resulta relevante para el análisis, lo verdaderamente importante es que su valor de 0.68 es positivo, ya que un R^2 negativo en el conjunto de validación sugeriría que el modelo se encuentra subajustado.

Después de analizar el comportamiento del modelo final contra el baseline y de evaluar las métricas más valiosas, otra herramienta crucial es el análisis visual del comportamiento del modelo. Por un lado, en la Figura 5 se puede observar el comportamiento del modelo con el conjunto de validación. Como resultado de entrenar el modelo con registros desde 1996 hasta 2018, se puede observar que el modelo logró aprender adecuadamente para realizar predicciones que se acerquen a los valores reales desde 2019 hasta 2025. Específicamente, en esta gráfica se puede ver que el modelo final logra capturar la estacionalidad de los datos, ya que parece repetir el mismo patrón que se presenta en cada año; en los datos reales se puede observar que a mitad de cada año hay siempre una caída en el volumen de producción de aguacate, y el modelo logra replicar tal comportamiento.

Igualmente, el modelo tiene una tendencia similar a la de los datos reales, no es exacta, pero sí logra acercarse bastante. Existen varios momentos en donde sí se realizan predicciones exactas, como por ejemplo, al inicio del año 2024 parece ser que la predicción coincide exactamente con el pico real. Si bien, en general el modelo no alcanza realmente los picos tanto de subida como de bajada, sus predicciones sí son cercanas y demuestran el comportamiento de la subida o de la bajada exactamente. Por ejemplo, desde el inicio hasta mediados del año 2019 las predicciones no coinciden exactamente en los picos de los datos reales, pero sí muestran el mismo comportamiento de disminución de volumen de producción de aguacate en ese instante de tiempo. Otro ejemplo, desde mediados del 2022 hasta el inicio del 2023 se puede ver que las predicciones no caen exactamente en los picos de los datos reales, pero sí muestran adecuadamente el comportamiento de subida en el volumen de producción de aguacate.

Por otro lado, otra gráfica que puede ser de ayuda para complementar el análisis visual es la Figura 6, en donde se puede confirmar que los residuos del modelo tienen una media de cero y que no existe ningún patrón presente, lo cual demuestra que el modelo ha capturado en su totalidad la estructura temporal de los datos. Complementando un poco más, también puede usarse la Figura 8 para confirmar que no existe autocorrelación debido a que casi en su totalidad los residuos se encuentran dentro de los límites de confianza.

Por último, otra herramienta importante para confirmar que el modelo final puede ser implementado en producción es el tiempo de entrenamiento. En la Figura 3 se puede observar que si bien, el modelo final no es el más rápido de todos en entrenarse, si es un tiempo muy eficiente, ya que tarda tan solo poco menos de un minuto, exactamente 56.52 segundos, y proporciona los mejores resultados. Esta duración en el entrenamiento es muy importante porque indica que el modelo tiene una gran facilidad de mantenimiento, lo cual lo vuelve viable para poder ser reentrenado y reajustado cuando se necesite.

Conforme al análisis presentado por estas 4 herramientas y considerando los criterios de éxito definidos en la Fase 0 del proyecto, se puede confirmar que el objetivo principal de esa fase fue cumplido por haber construido un modelo, utilizando datos históricos y variables explicativas, lo suficientemente robusto para poder ser implementado en producción y poder predecir con un grado de confianza aceptable el volumen de producción de aguacate en el estado de Jalisco de forma mensual, siendo de utilidad como insumo para la planeación productiva y el análisis de escenarios futuros.

Igualmente, este modelo logra responder las preguntas claves definidas en la Fase 0 del proyecto. Primeramente, este modelo sí logra demostrar el comportamiento de la oferta productiva de aguacate en Jalisco a lo largo del tiempo. Esto se demuestra principalmente en las predicciones realizadas sobre el conjunto de validación, donde se puede replicar ese comportamiento estacional en donde a mediados de cada año existe una caída en la oferta de aguacate.

Asimismo, contestando a lo que se preguntaba en la Fase 0, el modelo sí consigue identificar los patrones históricos más relevantes presentes a lo largo de todo el dataset. Esto se puede evidenciar en que el modelo pudo realizar predicciones adecuadas sobre el conjunto de entrenamiento y supo realizar predicciones sobre el conjunto de validación sin quedarse estancado en los patrones históricos de años anteriores, logrando adaptarse a las tendencias de los años posteriores.

De la misma forma, el modelo logra demostrar que sí se puede alcanzar una exactitud alta, así como lo demuestran las métricas analizadas, habiendo sido entrenado con relativamente pocos datos, menos de 300 registros en total. Adicionalmente, el modelo demuestra que sí es posible estimar de forma anticipada la oferta productiva mediante modelos predictivos de series de tiempo, ya que con el entrenamiento de datos históricos que comenzaban desde 1996, las predicciones realizadas sobre años recientes desde 2019 en el conjunto de validación siguen correctamente las tendencias reales.

B. Limitaciones

Si bien, como lo demostraron las herramientas empleadas para evaluar el modelo final, así como el cumplimiento de los criterios de éxito, que el modelo está listo para poder ser implementado en producción, hay que considerar que el modelo no toma en cuenta variables climatológicas, por lo que eventos esporádicos, como una helada, que lleguen a afectar la producción de aguacate no podrán ser contemplados. Sin embargo, parte de esta información puede llegar a verse

reflejada en variables que se usan para el modelo como lo es la superficie total cosechada o también el rendimiento.

Durante el desarrollo del proyecto se intentó integrar variables climatológicas al dataset para poder enriquecerlo, pero el principal problema fue la falta de esta información. Como nuestro dataset comenzaba con registros desde el año 1996, era muy complicado encontrar esta información por esas fechas y todavía más complicado agregada en registros mensuales para el estado de Jalisco. Por lo que se optó por integrar la información en registros con fechas particulares, por ejemplo, en una experimentación se añadió al dataset información sobre una helada confirmada en 2016 y un estrés hídrico desde 2022 hasta 2024, pero al realizar el entrenamiento con estos nuevos datos, los modelos resultantes no mejoraron, en esa experimentación el mejor modelo alcanzó una métrica MASE de 0.58, siendo entonces un modelo con un error 42% menor que el del baseline. Al no ver que la integración de esta información climatológica funcionara para mejorar significativamente los modelos, entonces se descartó.

De la misma forma, el modelo tampoco contempla eventos de choque, por lo que cualquier accidente relacionado con la maquinaria agrícola que llegue a causar cambios en la planeación productiva o genere atrasos en algún proceso, entonces no podrá ser considerado por el modelo.

Debido a la duración de la construcción de este proyecto, no se pudo dedicar más tiempo en encontrar información sobre eventos de choque en Jalisco que abarcaran desde los años 1996, o por lo menos en un rango de tiempo mensual consistente para las fechas más recientes o para la mayoría de los registros en el dataset.

Otra limitación más del modelo es que no considera el estado de salud de los cultivos. No se tiene alguna variable que refleje la existencia de alguna plaga que provoque el deterioro de los cultivos, derivando en la pérdida de cierta cantidad de aguacates o ralentizando el proceso de producción.

De la misma forma, el modelo está limitado a únicamente considerar el mercado de aguacate en Jalisco, por lo que fluctuaciones en la demanda internacional de aguacate que provoquen cambios en el volumen de producción nacional no será contemplado.

Finalmente, también existe una serie de factores que es ignorada por el modelo y que es difícil de integrar al dataset del modelo por su naturaleza esporádica y por su formato no estructurado, como lo son decisiones en la política internacional o incluso nacional que afecten a los productores para seguir con sus procesos habituales para la producción de aguacate.

C. Oportunidades de Mejora

A pesar de que el modelo final propuesto es lo suficientemente robusto para realizar predicciones confiables en un entorno de producción, definitivamente existe margen para mejorar aún más su rendimiento. Principalmente en las limitaciones presentadas del modelo es en donde se encuentran las áreas de oportunidad más significativas.

Integrar variables climatológicas en el dataset es el punto con mayor potencial para mejorar el modelo. Se debe de tomar más tiempo en buscar y recopilar dicha información y que abarque el

rango completo del tiempo del dataset, es decir que los datos más viejos de 1996 cuenten con esta información, así como los más actuales, o por lo menos asegurarse de que la mayoría de los registros cuenten con estos datos, con el fin de que el modelo tenga más información para ser entrenado y se puedan identificar patrones más complejos, ahora considerando el clima.

Esta nueva mejora puede aumentar incluso la utilidad del modelo para el negocio ya que podría ser empleado directamente para realizar predicciones con eventos catastróficos para el cultivo de aguacates para poder anticiparse adecuadamente a estos escenarios.

Igualmente, es importante integrar en un futuro datos sobre eventos de choque al dataset que, de la misma forma, abarquen todas las fechas del dataset, o la mayoría por lo menos, de manera mensual. Este nuevo cambio puede volver al modelo más preciso al contemplar directamente situaciones que ocurren en el campo que pueden llegar a ralentizar ciertos procesos de cultivo.

Nuevamente esta integración puede darle una nueva utilidad adicional al modelo para que el negocio pueda emplearlo para pronosticar su producción de aguacate en el caso de la existencia de ciertos incidentes recientes.

Otra área de oportunidad es la integración de variables adicionales que contengan información sobre costos que se tienen que asumir mensualmente, por ejemplo, que se consideren los costos totales requeridos por fertilizantes, agroquímicos y de mano de obra, los cuales son factores que por la fluctuación de sus costos pueden llevar a que se necesiten ajustar ciertos procesos que directamente afecten la producción de aguacate.

Por último, un área de oportunidad que puede volver definitivamente más exacto al modelo es el aumento en el tamaño de registros en el dataset. Si bien el modelo abarca información entre un vasto periodo desde 1996 hasta 2025, los datos son registros mensuales. El buscar información entre ese mismo periodo de tiempo o incluso un poco más reducido, pero a una frecuencia quincenal o incluso semanal, puede aumentar la cantidad de datos y brindar una mayor resolución en las predicciones, pudiendo construir un modelo más robusto y que incluso permita realizar predicciones en una fecha más específica.

VI. VIABILIDAD DE IMPLEMENTACIÓN.

Partiendo del análisis exhaustivo de los resultados obtenidos con el modelo Stacking RF, así como de las limitaciones y viabilidades de mejora identificadas a lo largo del proyecto, y tomando como referencia la metodología CRISP-ML como apoyo para la evaluación. En la siguiente sección se fundamenta la viabilidad de implementar el modelo. Para ello, se describen los escenarios de uso para APEAJAL, las recomendaciones para una implementación adecuada, los accionables específicos para los stakeholders y las acciones necesarias para el mantenimiento continuo del sistema.

A. Escenarios de uso

Este modelo fue establecido desde un inicio como una herramienta de apoyo estratégico para APEAJAL, quien agrupa a diversos productores y actores clave de la cadena de valor del aguacate en la región. Por ello, son los directivos, técnicos y productores de la asociación quienes harán uso principal del modelo, empleándolo como herramienta para la toma de decisiones.

Para poder hacer uso de este modelo, los miembros de APEAJAL con acceso al sistema podrán utilizarlo como una herramienta estratégica, orientada a atender las necesidades del negocio tomando en cuenta las capacidades demostradas del modelo a lo largo de este proyecto.

Entre los escenarios en donde podría emplearse, se identificaron las siguientes situaciones. El primero es la planificación mensual de la producción, cuyo objetivo es estimar el volumen de producción de manera anticipada. Como se demostró en el análisis de desempeño del modelo, particularmente en la Figura 5, la producción del aguacate presenta un comportamiento estacional recurrente. Por medio de estas estimaciones, será posible identificar y anticipar periodos de alta o baja oferta, generando un impacto positivo en la cadena de valor de la producción de aguacate de la región. Dado que el modelo captura esta estacionalidad característica, sus predicciones pueden ayudar a la asignación de recursos, la programación de actividades de cosecha y empaque, y la definición de costos, complementando con una perspectiva basada en datos históricos el análisis que habitualmente realizan los especialistas del sector.

Como segundo escenario se encuentra el soporte para negociaciones comerciales. Como ya se mencionaba, APEAJAL opera en un mercado caracterizado por fluctuaciones de demanda y factores externos que influyen directamente en la producción. Contar con una estimación anticipada del volumen disponible le permite a la asociación negociar con mayor certeza los compromisos de exportación, apoyando decisiones sobre logística y almacenamiento con base en proyecciones fundamentadas en los patrones históricos de la región.

B. Recomendaciones

Con base en el análisis de los resultados obtenidos y considerando las limitaciones identificadas en el modelo, se identificaron las siguientes recomendaciones para garantizar una implementación sostenible.

En primer lugar, se recomienda establecer un periodo de reentrenamiento periódico, dado que los patrones de producción agrícola pueden evolucionar con el tiempo, es fundamental definir un calendario de reentrenamiento del modelo, considerando como mínimo una actualización mensual que incorpore los datos de producción más recientes disponibles. Asimismo, se sugiere establecer umbrales en las métricas de desempeño que activen automáticamente un proceso de reentrenamiento en caso de detectar un cambio drástico en los resultados.

Debido a que el modelo no está considerado como la herramienta definitiva para la toma de decisiones, sino como un apoyo, se recomienda analizar sus resultados con la participación activa de especialistas del sector, quienes podrán interpretar las predicciones considerando factores que el modelo no contempla.

Adicionalmente, se recomienda enriquecer el dataset a futuro con variables climatológicas, costos agrícolas y datos sobre eventos de choque, en colaboración con organizaciones como el Servicio Meteorológico Nacional, el Sistema de Información Agroalimentaria y Pesquera (SIAP) y los registros internos de los productores asociados, con el objetivo de mejorar la precisión del modelo en versiones futuras. También, como parte de una evaluación inicial del sistema, se recomienda realizar un despliegue en un servidor interno que permita validar el funcionamiento completo antes de considerar una migración hacia infraestructura en la nube. En paralelo, se sugiere ofrecer capacitaciones a los usuarios y técnicos de APEAJAL para explicarles el alcance del modelo, la interpretación de sus resultados y la identificación de señales de bajo rendimiento, estas sesiones se deberían repetir cada vez que se presenten actualizaciones significativas en el sistema. Finalmente, se recomienda mantener una documentación actualizada del sistema predictivo que facilite su comprensión ante nuevos usuarios o durante auditorías.

C. Accionables por Stakeholder

Como tareas específicas para los stakeholders, se identificaron tres perfiles principales dentro de APEAJAL. Los directivos de la asociación, responsables de las decisiones estratégicas. Los técnicos y analistas, encargados del manejo de los datos, la ejecución del modelo con cada nuevo dato disponible y la validación de que el error no supere los umbrales establecidos. Y los productores asociados, quienes pueden contribuir con datos de campo relevantes, como registros de cosecha, incidentes o afectaciones, que enriquezcan futuras versiones del modelo. En la siguiente tabla se especifican los accionables identificados con su asignación y plazo correspondiente:

TABLA I
Accionables por stakeholder

Accionable	Responsable	Plazo
Validar el modelo con datos recientes y registrar desviaciones.	Técnicos / Analistas	2-4 semanas
Desplegar el modelo en servidor local.	Técnicos / Analistas	1-2 meses
Establecer y documentar el protocolo de reentrenamiento mensual.	Técnicos / Analistas	1-2 meses
Capacitar a directivos y técnicos en la interpretación de predicciones y límites del modelo.	Directivos / Técnicos	1-2 meses
Recopilar datos sobre eventos de choque y variables climatológicas para enriquecer el dataset.	Técnicos / Productores asociados	3-6 meses

Accionable	Responsable	Plazo
Evaluar la migración hacia infraestructura en la nube una vez validado el sistema local.	Directivos / Técnicos	6-12 eses

D. Mantenimiento

Por medio del mantenimiento continuo del sistema es posible preservar su utilidad a lo largo del tiempo, ya que un modelo que no se actualiza periódicamente puede ver afectado su desempeño conforme las condiciones del sistema van cambiando. A este fenómeno se le conoce como *model drift* y debe evitarse para mantener el sistema vigente.

Algunas de las estrategias que pueden implementarse para lograrlo son las siguientes. En primer lugar, implementar el monitoreo automático de las métricas de desempeño, específicamente el MAE y el RMSE, dado que permiten detectar incrementos en el error de predicción. Si en algún punto el error supera el umbral establecido, deberá ejecutarse un proceso de reentrenamiento del modelo. En adición a lo anterior, y sin la necesidad de detectar un cambio en las métricas, se recomienda establecer un reentrenamiento periódico de frecuencia mensual. Este proceso debe apoyarse en algún sistema de control de versiones que permita comparar automáticamente el desempeño del modelo actualizado contra el anterior, garantizando que solo se reemplace el modelo en producción, todo ello supervisado por el técnico encargado de trabajar con los datos.

Otro aspecto que podría verse afectado son los factores externos como regulaciones de exportación, modificaciones en políticas comerciales o cambios en el mercado. Por lo que se recomienda llevar a cabo una revisión anual del sistema, ya que este tipo de cambios no ocurren con alta frecuencia, pero sí son importantes de considerar dentro del historial de datos.

VII. PROPUESTA DE ENTORNO DE PRODUCCIÓN

El desarrollo del modelo predictivo constituye únicamente la primera etapa dentro del ciclo de vida de un sistema de analítica avanzada. Para que los resultados obtenidos puedan generar valor operativo, es necesario implementar una infraestructura que permita gestionar datos, reproducir experimentos, desplegar el modelo y monitorear su desempeño de forma continua.

En esta sección se propone una arquitectura de producción basada en principios de MLOps, cuyo objetivo es garantizar la reproducibilidad, trazabilidad y mantenimiento del modelo a lo largo del tiempo. La propuesta considera herramientas ampliamente utilizadas en la industria, tales como DVC para el versionado de datos, MLflow para el seguimiento de experimentos, y el despliegue del modelo mediante servicios de inferencia accesibles a través de una API.

El entorno planteado permitiría a organizaciones como la APEAJAL integrar el modelo dentro de procesos de toma de decisiones basados en datos, manteniendo control sobre la evolución del sistema y facilitando futuras mejoras del modelo.

A. Arquitectura General

La arquitectura propuesta sigue un enfoque modular que separa las etapas de gestión de datos, entrenamiento del modelo, despliegue y monitoreo, permitiendo escalar el sistema de manera progresiva.

El flujo general del sistema puede describirse en las siguientes etapas:

- 1. Ingesta de datos: recopilación periódica de información histórica de producción y variables externas relevantes.
- 2. Versionado de datos: almacenamiento controlado de los conjuntos de datos utilizados para entrenamiento y validación.
- 3. Entrenamiento del modelo: ejecución del pipeline de entrenamiento y optimización del modelo.
- 4. Registro de experimentos: almacenamiento de métricas, hiper-parámetros y artefactos generados durante el entrenamiento.
- 5. Despliegue del modelo: publicación del modelo seleccionado como servicio de predicción.
- 6. Consumo de predicciones: acceso a las predicciones mediante una API o tableros analíticos.
- 7. Monitoreo del modelo: seguimiento del desempeño y detección de degradación.
- 8. Reentrenamiento: actualización del modelo cuando se detecten cambios en los datos o en el desempeño.

Este enfoque permite mantener una separación clara entre entrenamiento y operación, reduciendo riesgos y facilitando la reproducibilidad de los resultados.




Fig. 10. Arquitectura MLOps

B. Versionado de Datos y Modelos (DVC)

Uno de los principales desafíos en proyectos de aprendizaje automático es garantizar la reproducibilidad de los experimentos. En este proyecto se propone utilizar DVC (*Data Version Control*) para gestionar versiones de los conjuntos de datos y artefactos del modelo.

DVC permite mantener un control detallado sobre:

- Conjuntos de datos utilizados en cada experimento
- Versiones de los modelos entrenados
- Dependencias entre etapas del pipeline

- Reproducibilidad de los resultados obtenidos

A diferencia de sistemas tradicionales de control de versiones como Git, DVC está diseñado específicamente para trabajar con archivos de gran tamaño, lo que lo convierte en una solución adecuada para proyectos de ciencia de datos.

El uso de DVC permitiría mantener un registro completo de la evolución del modelo, facilitando auditorías, replicación de resultados y comparaciones entre diferentes versiones del sistema.

C. Seguimiento de Experimentos (MLflow)

Durante el desarrollo del modelo se evaluaron múltiples algoritmos y configuraciones de hiper-parámetros. Para gestionar este proceso de manera sistemática, se propone utilizar MLflow como plataforma de seguimiento de experimentos.

- MLflow permite registrar automáticamente:
- Hiper-parámetros utilizados
- Métricas de evaluación
- Artefactos generados
- Versiones de modelos entrenados

Esto facilita comparar distintos experimentos y seleccionar el modelo con mejor desempeño.

En un entorno productivo, MLflow también puede funcionar como un registro centralizado de modelos (*Model Registry*), permitiendo gestionar estados como:

- Modelo en desarrollo
- Modelo en validación
- Modelo en producción

Esta funcionalidad es especialmente útil cuando múltiples equipos participan en el desarrollo y mantenimiento del sistema.

D. Pipeline de Entrenamiento

Para garantizar consistencia en el proceso de entrenamiento del modelo, se propone implementar un pipeline automatizado que ejecute las siguientes etapas:

1. Preparación y limpieza de datos
2. Generación de variables derivadas
3. Entrenamiento de modelos base
4. Generación de meta-características
5. Entrenamiento del modelo de ensamble
6. Evaluación del desempeño
7. Registro de resultados

La automatización de este proceso permite asegurar que cada entrenamiento siga exactamente los mismos pasos, reduciendo errores humanos y facilitando la reproducibilidad.

Este pipeline puede ejecutarse:

- De forma manual

- Mediante tareas programadas
- Como parte de un sistema de integración continua

E. Despliegue del Modelo

Una vez seleccionado el modelo final, este debe ponerse a disposición de los usuarios mediante un mecanismo de inferencia accesible.

La estrategia propuesta consiste en desplegar el modelo como un servicio de inferencia, empaquetado dentro de un contenedor reproducible.

El flujo de despliegue sería:

1. Exportar el modelo entrenado
2. Encapsular el modelo dentro de un servicio de predicción
3. Ejecutar el servicio por medio de contenedores
4. Desplegarlo en infraestructura de nube o servidor dedicado

Este enfoque permite escalar el servicio de predicción y actualizar el modelo sin afectar a los sistemas que consumen las predicciones.

F. API de Predicción

El acceso al modelo puede realizarse mediante una API REST, la cual permite integrar el sistema predictivo con otras aplicaciones o plataformas analíticas.

La API recibiría como entrada variables relevantes del contexto actual (por ejemplo, mes o condiciones externas) y devolvería como salida la predicción de la oferta de producción de aguacate.

Ejemplo conceptual de solicitud:

```
POST /predict
{
  "mes": 5,
  "año": 2026
}
```

Respuesta:

```
{
  "prediccion_produccion": 0.72
}
```

Este enfoque permite integrar fácilmente el modelo con:

- Tableros de inteligencia de negocios
- Sistemas de planeación agrícola
- Herramientas de análisis económico

G. Monitoreo del Modelo

Una vez desplegado, el modelo debe ser monitoreado de forma continua para detectar posibles degradaciones en su desempeño.

El monitoreo puede incluir:

- Seguimiento de métricas de error
- Análisis de desviaciones entre predicciones y valores reales
- Detección de cambios en la distribución de datos
- Identificación de eventos atípicos

El objetivo del monitoreo es identificar situaciones en las que el modelo deja de representar adecuadamente la dinámica del fenómeno analizado.

Esto es particularmente relevante en el caso de la producción agrícola, donde factores externos como clima, política comercial o cambios en la demanda pueden alterar los patrones históricos.

H. Reentrenamiento Automatizado

Cuando se detecta degradación en el desempeño del modelo o se dispone de nuevos datos relevantes, es recomendable ejecutar un proceso de reentrenamiento del modelo.

El sistema propuesto permitiría realizar este proceso de forma automatizada mediante:

1. Incorporación de nuevos datos al repositorio versionado
2. Ejecución del pipeline de entrenamiento
3. Evaluación comparativa con el modelo actual
4. Actualización del modelo en producción si se obtiene una mejora significativa

Este ciclo de mejora continua permite mantener actualizado el modelo y asegurar que las predicciones reflejen las condiciones más recientes del sistema productivo.

VIII. EVALUACIÓN DE PLATAFORMAS EN LA NUBE

Una vez desarrollado el modelo predictivo y definida una arquitectura de producción basada en prácticas de MLOps, es necesario analizar las alternativas tecnológicas disponibles para su implementación en un entorno operativo.

Las plataformas de computación en la nube ofrecen servicios especializados para el despliegue y operación de modelos de aprendizaje automático, incluyendo infraestructura escalable, herramientas de monitoreo y servicios administrados para la gestión del ciclo de vida de modelos. Sin embargo, dependiendo de la complejidad del sistema y de los recursos disponibles en la organización, también puede ser viable implementar el modelo en infraestructura propia.

En el contexto de la APEAJAL, donde el sistema predictivo se utilizaría principalmente como una herramienta de apoyo para el análisis de tendencias de producción, resulta pertinente evaluar diferentes opciones de infraestructura considerando factores como costo, facilidad de implementación, escalabilidad y mantenimiento.

Por esta razón, se realizó una comparación entre cinco alternativas tecnológicas:

- Amazon Web Services (AWS)

- Microsoft Azure
- Google Cloud Platform (GCP)
- IBM Watson
- Infraestructura local o servidor propio

El objetivo de esta evaluación es identificar la opción que permita desplegar el modelo de manera eficiente y sostenible, considerando las necesidades operativas del proyecto.

A. Criterios de Evaluación

Para comparar las distintas plataformas se definieron varios criterios relevantes desde una perspectiva técnica y operativa.

En primer lugar, se consideró la facilidad de integración, entendida como la capacidad de la plataforma para integrarse con herramientas utilizadas en el proyecto, como pipelines de entrenamiento, control de versiones y servicios de inferencia.

Otro criterio relevante es la escalabilidad, es decir, la capacidad de la plataforma para adaptarse a incrementos en la demanda de procesamiento o en el volumen de datos. Aunque el modelo desarrollado en este proyecto no requiere grandes recursos computacionales, la posibilidad de escalar el sistema puede ser relevante en el futuro si se incorporan nuevas fuentes de datos o modelos más complejos.

También se evaluó el costo operativo, incluyendo tanto el costo de infraestructura como el esfuerzo requerido para mantener el sistema en funcionamiento.

Adicionalmente, se consideró la facilidad de despliegue, que se refiere a la disponibilidad de herramientas que simplifiquen la publicación del modelo como servicio de predicción.

Finalmente, se evaluó el nivel de soporte para flujos de MLOps, incluyendo capacidades para el seguimiento de experimentos, gestión de modelos y monitoreo del desempeño.

Estos criterios permiten comparar las distintas alternativas de infraestructura desde una perspectiva integral, considerando tanto factores técnicos como organizacionales.

B. Comparación de Proveedores

A continuación, se presenta una comparación entre distintas plataformas tecnológicas que pueden utilizarse para el despliegue del modelo predictivo desarrollado en este proyecto.

Las principales plataformas de computación en la nube (*Amazon Web Services*, *Microsoft Azure* y *Google Cloud Platform*) ofrecen servicios especializados para el desarrollo y despliegue de modelos de aprendizaje automático. Estas plataformas incluyen herramientas administradas para entrenamiento de modelos, gestión de experimentos y despliegue de servicios de inferencia.

Por otra parte, IBM Watson proporciona soluciones orientadas específicamente a inteligencia artificial empresarial, aunque suele enfocarse en organizaciones con requerimientos más complejos y mayores presupuestos de infraestructura.

Finalmente, también se consideró la alternativa de implementar el sistema en infraestructura propia, utilizando un servidor web administrado por la organización. Esta opción

puede resultar adecuada cuando el modelo tiene requerimientos computacionales moderados y el número de solicitudes de predicción es relativamente bajo.

Dado que el modelo desarrollado en este proyecto tiene un tamaño moderado y su uso previsto corresponde principalmente a análisis periódicos y consultas de predicción, todas las alternativas mencionadas resultan técnicamente viables.

En la siguiente tabla podemos ver un comparativo entre las cinco plataformas evaluadas, en una escala de 1 a 5; un mayor puntaje implica una ventaja, por ejemplo, un valor de 5 en costo indica que es la plataforma más económica.

Criterio					
Facilidad de Implementar	4	4	4	3	3
Escalabilidad	5	5	5	4	1
Costo	3	3	3	2	5
Soporte MLOps	5	5	5	3	1

Fig. 11. Comparativo de Plataformas

Algunos puntos por resaltar son:

- AWS cuenta con un amplio ecosistema para aplicaciones de aprendizaje automático.
- Como es de esperarse, Azure tiene una fuerte integración con herramientas Microsoft.
- GCP también tiene mucha fortaleza en temas de analítica y gestión de datos.
- IBM Watson está orientado a empresas grandes.
- La posibilidad de realizar el despliegue en infraestructura local dependerá de las capacidades de cómputo y ambientes operativos disponibles; para aclarar esto, será necesario investigar en el departamento de sistemas de APEAJAL

Servicios clave de cada plataforma:

- AWS: SageMaker, App Runner/ECS Fargate.
- Azure: Azure ML, Azure Container Instances/Apps.
- GCP: Vertex AI, Cloud Run.
- IBM: Watson ML, Cloud Code Engine.
- Infraestructura local: las herramientas descritas en la sección de arquitectura, más algún motor de ejecución de contenedores Docker.

C. **Proveedor Recomendado**

Para la implementación del servicio de predicción basado en el modelo desarrollado en este proyecto, se realizó un análisis comparativo entre distintas alternativas de infraestructura tecnológica, considerando factores como escalabilidad, costo operativo, facilidad de implementación e integración con herramientas de MLOps.

Dado que el sistema propuesto consiste principalmente en un servicio de predicción basado en un modelo previamente entrenado, sus requerimientos computacionales son relativamente moderados. Por lo tanto, resulta viable considerar soluciones en la nube como infraestructuras locales administradas por la propia organización.

Estrategia de Despliegue Inicial: Infraestructura Local

Como primera etapa de implementación, se propone utilizar una infraestructura local para el despliegue inicial del sistema.

El uso de un servidor propio permite validar la integración completa del sistema, incluyendo el contenedor Docker del modelo, la API de predicción (por ejemplo, mediante FastAPI o Flask) y los flujos de ingestión de datos, sin incurrir en costos asociados a infraestructura en la nube o transferencia de datos.

Este enfoque resulta particularmente adecuado para fases de prueba de concepto (PoC) o para entornos de validación interna donde se requiere comprobar el correcto funcionamiento del sistema antes de habilitar su disponibilidad general.

Entre las principales ventajas de esta estrategia se encuentran:

- Aprovechamiento de infraestructura tecnológica existente.
- Control directo sobre la seguridad y privacidad de los datos.
- Costos operativos reducidos durante la fase inicial del proyecto.

No obstante, esta alternativa presenta limitaciones en términos de escalabilidad y mantenimiento, ya que la organización sería responsable de administrar la infraestructura, incluyendo actualizaciones del sistema, disponibilidad del servidor y gestión de seguridad.

Recomendación Principal: Google Cloud Platform (GCP)

Una vez validado el funcionamiento del sistema, se recomienda migrar el despliegue hacia una plataforma de nube pública que permita escalar el servicio de predicción de manera más flexible y eficiente.

Entre las plataformas evaluadas, Google Cloud Platform (GCP) se identifica como la opción más adecuada para este proyecto.

GCP ofrece un ecosistema robusto de herramientas para el desarrollo y operación de sistemas de aprendizaje automático. En particular, servicios como Vertex AI y Cloud Run permiten desplegar modelos de manera sencilla mediante contenedores, manteniendo compatibilidad con arquitecturas modernas basadas en microservicios.

El uso de Cloud Run resulta especialmente atractivo debido a su modelo serverless, en el cual la infraestructura se escala automáticamente en función de la demanda. Este enfoque permite optimizar costos operativos, ya que el sistema únicamente genera gastos cuando se reciben solicitudes de predicción.

Entre las ventajas principales de esta plataforma se encuentran:

- Escalabilidad automática ante incrementos en la demanda de predicciones.
- Modelo de pago por uso que evita costos fijos innecesarios.
- Integración sencilla con herramientas de análisis de datos y procesamiento de información.
- Facilidad para desplegar aplicaciones basadas en contenedores Docker.

Estas características hacen de GCP una plataforma particularmente adecuada para proyectos donde el sistema predictivo se utiliza como herramienta de apoyo para la toma de decisiones, con cargas de trabajo variables.

Alternativa Tecnológica: Microsoft Azure

Como alternativa cercana a la recomendación principal, Microsoft Azure también representa una plataforma sólida para el despliegue del sistema.

Azure cuenta con el servicio Azure Machine Learning, que ofrece capacidades avanzadas para la gestión del ciclo de vida de modelos de aprendizaje automático, incluyendo herramientas para monitoreo del desempeño, automatización de pipelines de entrenamiento y detección de deriva de datos.

Además, Azure presenta ventajas importantes en organizaciones que ya utilizan herramientas del ecosistema Microsoft, debido a su integración con servicios como Azure DevOps, GitHub Actions y Active Directory.

Sin embargo, en comparación con GCP, la plataforma puede presentar una mayor complejidad inicial en la configuración de recursos y gestión de servicios, lo que puede representar una curva de aprendizaje más pronunciada para equipos pequeños.

Resumen de Propuesta de Infraestructura

Con base en el análisis realizado, se propone una estrategia de implementación en dos etapas.

En una primera fase, se recomienda desplegar el sistema en infraestructura local, permitiendo validar el funcionamiento del modelo, la API de predicción y los flujos de integración con los sistemas de la organización.

Posteriormente, una vez validada la estabilidad del sistema y en caso de requerirse mayor disponibilidad o escalabilidad, se sugiere migrar el despliegue hacia Google Cloud Platform, aprovechando sus capacidades de infraestructura serverless y su facilidad de integración con aplicaciones basadas en contenedores.

Este enfoque gradual permite equilibrar viabilidad económica, simplicidad operativa y escalabilidad tecnológica, garantizando que la solución propuesta pueda evolucionar conforme aumenten las necesidades analíticas de la organización.

IX. CONCLUSIONES

El presente proyecto analizó la capacidad de distintos modelos de aprendizaje automático para predecir la producción de aguacate en Jalisco a partir de series temporales históricas. Los resultados muestran que los modelos de ensamble pueden

mejorar el desempeño predictivo respecto a los modelos individuales. En particular, el modelo Stacking con Random Forest como metamodelo obtuvo el mejor desempeño global entre las alternativas evaluadas, logrando capturar de forma adecuada la tendencia general y la estacionalidad presentes en la serie.

Gracias al análisis individual del modelo y complementándolo con los criterios de aceptación previamente definidos en la Fase 0, se puede confirmar que el modelo puede ser implementado en el entorno de producción y que sus predicciones son confiables para el negocio. El criterio de aceptación principal fue cumplido al identificar que el modelo final propuesto logró superar al modelo baseline definido en entregas pasadas, demostrando que la complejidad de este modelo final es necesaria para realizar predicciones más robustas. No obstante, sigue existiendo un margen para mejorar el rendimiento del modelo, como lo es la integración de variables que contemplen el clima, factores de choque y costos relacionados a la adquisición de fertilizantes, agroquímicos y mano de obra, al igual que el aumento en el tamaño del dataset para que con una mayor cantidad de registros, ya sea en otra frecuencia como semanal o quincenal, se puedan realizar predicciones más exactas en un tiempo más específico.

De la misma forma, el análisis de los resultados sugiere que el modelo final logra reproducir los patrones históricos más relevantes de la producción. Sin embargo, como es común en modelos basados únicamente en información histórica, su capacidad para anticipar cambios abruptos o eventos extraordinarios es limitada. Estas variaciones probablemente están asociadas con factores externos no incluidos en el conjunto de datos, como condiciones climáticas, plagas, fluctuaciones en la demanda internacional o decisiones de política comercial.

Con respecto a la viabilidad del modelo, se identificaron dos escenarios principales para su uso los cuales fueron la planificación mensual de la producción y el soporte para negociaciones comerciales, ambos alineados con las necesidades estratégicas de la asociación. Para garantizar una implementación sostenible, se formularon recomendaciones orientadas tanto al aspecto técnico como funcional, destacando la importancia de establecer un protocolo de reentrenamiento mensual, complementar las predicciones con la ayuda de especialistas del sector y capacitar a los usuarios que planean usar el modelo. Asimismo, se definieron accionables específicos asignados a los distintos perfiles de stakeholders identificados dentro de APEAJAL, considerando plazos de ejecución. Finalmente, se propuso una estrategia de mantenimiento continuo basada en el monitoreo automático de métricas y revisiones periódicas del sistema, con el fin de prevenir la degradación del modelo y asegurar su vigencia a lo largo del tiempo.

Desde una perspectiva aplicada, el modelo desarrollado puede utilizarse como herramienta de apoyo analítico para la estimación preliminar de la producción, permitiendo generar escenarios basados en el comportamiento histórico y complementando el análisis realizado por especialistas del sector. Para facilitar su uso en entornos operativos, el proyecto también propone una arquitectura de producción que incluye prácticas de versionado de datos y modelos, seguimiento de

experimentos, monitoreo del desempeño y reentrenamiento automatizado, lo que permitiría mantener la calidad del sistema predictivo a lo largo del tiempo.

Finalmente, la evaluación comparativa de plataformas tecnológicas sugiere que el despliegue del modelo podría implementarse tanto en servicios de nube pública como AWS, Azure o Google Cloud, como en una infraestructura propia mediante un servidor institucional, dependiendo de las restricciones presupuestarias y operativas de la organización. En trabajos futuros, la incorporación de variables exógenas relevantes (clima, precios internacionales, superficie cultivada, entre otras) y la exploración de modelos más sensibles a cambios estructurales podrían mejorar aún más la capacidad predictiva del sistema y su utilidad para organizaciones como la Asociación de Productores Exportadores de Aguacate de Jalisco.

REFERENCIAS

- [1] Banco de México, 'Sistema de Información Económica (SIE), Cuadro CE37,' Banxico, s.f. Disponible en: <https://www.banxico.org.mx/SieInternet/consultarDirectorioInternetAction.do?sector=1&accion=consultarCuadro&idCuadro=CE37&locale=es>. Accedido: 23-ene.-2026.
- [2] Instituto Nacional de Estadística y Geografía (INEGI), 'Comercio exterior. Datos abiertos,' INEGI, s.f. Disponible en: https://www.inegi.org.mx/programas/comext/#datos_abiertos. Accedido: 23-ene.-2026.
- [3] Instituto Nacional de Estadística y Geografía (INEGI), 'Producto Interno Bruto (PIB). Tabulados,' INEGI, s.f. Disponible en: <https://www.inegi.org.mx/temas/pib/#tabulados>. Accedido: 23-ene.-2026.
- [4] Productores de Aguacate, 'Revista MODULA,' Productores de Aguacate, s.f. Disponible en: <https://www.productoresdeaguacate.com/MODULArevista/modulos/web/www/index.php>. Accedido: 23-ene.-2026.
- [5] Procuraduría Federal del Consumidor (PROFECO), 'Quién es Quién en los Precios. Datos abiertos,' PROFECO, s.f. Disponible en: https://datos.profecogob.mx/datos_abiertos/qqp.php. Accedido: 23-ene.-2026.
- [6] Secretaría de Agricultura y Desarrollo Rural, 'Cierre agrícola,' AGRICULTURA, s.f. Disponible en: https://nube.agricultura.gob.mx/cierre_agricola/. Accedido: 23-ene.-2026.
- [7] Secretaría de Agricultura y Desarrollo Rural, 'Datos abiertos del sector agrícola,' AGRICULTURA, s.f. Disponible en: <https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>. Accedido: 23-ene.-2026.
- [8] Servicio Nacional de Sanidad, Inocuidad y Calidad Agroalimentaria (SENASICA), 'Estadística de producción de aguacate,' SIAS, s.f. Disponible en: <https://dj.senasica.gob.mx/sias/Statistics/Transversal/EstadisticaProduccionAguacate>. Accedido: 23-ene.-2026.
- [9] United States International Trade Commission (USITC), 'DataWeb: Importaciones generales por HTS,' USITC, s.f. Disponible en: <https://dataweb.usitc.gov/trade/search/GenImp/HTS>. Accedido: 28-ene.-2026.
- [10] S. Galli, Python Feature Engineering Cookbook, 2nd ed., Packt Publishing, 2022.
- [11] Towards Data Science, 'Codificación cíclica,' s.f. Disponible en: <https://towardsdatascience.com/cyclical-encoding-an-alternative-to-one-hot-encoding-for-time-series-features-4db46248ebba/>. Accedido: 7-feb.-2026.
- [12] R. J. Hyndman y G. Athanasopoulos, 'Series de Fourier,' OTexts, s.f. Disponible en: <https://otexts.com/fpp3/useful-predictors.html#fourier-series>. Accedido: 7-feb.-2026.
- [13] Regresión lineal con Scikit-Learn, LEARN STATISTICS EASILY, 13-feb.-2024.
- [14] Regresión Ridge (Scikit-learn), CDS Institute, 13-sep.-2025.
- [15] Lasso (Scikit-learn), CDS Institute, 13-sep.-2025.
- [16] Naïve forecasting, Llamasoft, s.f.
- [17] 'How to interpret ARIMA(0,1,0),' Cross Validated, 27-oct.-2017.
- [18] 'ARIMA forecast with python statsmodels,' Stack Overflow, s.f.
- [19] Arize, 'R-squared — Understanding the coefficient of determination,' 2023.
- [20] A. Smith, 'The foundation of model evaluation,' Medium, 2023.
- [21] T. R. Alper, 'Introduction to Gaussian Process Regression Part 1,' Medium, 2020.
- [22] A. Damianou y N. Lawrence, 'Deep Gaussian Processes,' arXiv, 2020.
- [23] GeeksforGeeks, 'Gaussian Process Regression (GPR),' s.f.
- [24] Data Science Collective, 'Future Forecasting of Time Series Using LSTM,' Medium, 2020.
- [25] J. Brownlee, Mastering Time Series Forecasting, Machine Learning Mastery, 2020.
- [26] Z. Smith, 'Advances in Time Series Forecasting,' arXiv, 2024.
- [27] S. Olumide, 'How to Implement ARIMA Modeling in Python,' Statology, 13-may.-2025.
- [28] A. Williams, 'Python Statsmodels SARIMAX,' PY Tutorial, 21-ene.-2025.
- [29] scikit-learn, 'MLPRegressor documentación,' 2026.
- [30] scikit-learn, 'SVR documentación,' 2026.
- [31] TecMNA2025MLOpsEq25, "mna-mlops-sep2025-eq25," GitHub repository, 2025. Disponible en: <https://github.com/TecMNA2025MLOpsEq25/mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.
- [32] Equipo 25, "servicio-mna-mlops-sep2025-eq25," DockerHub repository, 2025. Disponible en: <https://hub.docker.com/r/jplopezs/servicio-mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.