



Modelo Predictivo de la Oferta de Producción de Aguacate en Jalisco

Asociación de Productores Exportadores de Aguacate de Jalisco

Resumen Ejecutivo (Artículo Científico)

Profesores

Titular: Dra. Grettel Barceló Alonso
Titular: Dr. Luis Eduardo Falcón Morales

Asesor

Dr. Gerardo Jesús Camacho González

Patrocinadores

Dr. Jorge Antonio Ascencio Gutiérrez
Yanmei King Loeza

Equipo 29

Carolina Lucas Dophe – [A01702450](#)
Juan Pablo López Sánchez – [A01313663](#)
Víctor Hugo Soto Herrera – [A01706446](#)

Tabla de Contenido

ABSTRACT	3
1. INTRODUCCIÓN	4
2. TRABAJO RELACIONADO	5
3. METODOLOGÍA	6
3.1 FORMULACIÓN DEL PROBLEMA	6
3.2 ANÁLISIS EXPLORATORIO DE DATOS	6
3.3 MODELOS PREDICTIVOS EVALUADOS	7
3.4 MODELOS DE ENSAMBLE	8
3.5 VALIDACIÓN Y EVALUACIÓN DE MODELOS	9
3.6 SELECCIÓN DEL MODELO FINAL	12
4. EXPERIMENTACIÓN	13
4.1 CONJUNTO DE DATOS	13
4.2 DIVISIÓN DE DATOS	13
4.3 MODELOS EVALUADOS	13
4.4 EVALUACIÓN EXPERIMENTAL	16
5. RESULTADOS	17
5.1 ANÁLISIS DE DESEMPEÑO CUANTITATIVO	17
5.2 ANÁLISIS VISUAL Y DE RESIDUOS	19
6. DISCUSIÓN	22
6.1 FUNDAMENTACIÓN DEL ÉXITO DEL MODELO FINAL	22
6.2 RAZONES DEL BAJO DESEMPEÑO EN MODELOS COMPLEJOS	22
6.3 ANÁLISIS DE FALLAS Y PICOS ABRUPTOS	22
7. CONCLUSIONES	23
REFERENCIAS	24

Abstract

Este trabajo presenta un enfoque de modelado predictivo diseñado para estimar la producción futura de aguacate en el estado de Jalisco, empleando técnicas de análisis de series temporales y aprendizaje automático. A partir de datos históricos de producción agrícola, se evaluaron diversos modelos que incluyen desde métodos estadísticos tradicionales hasta redes neuronales y algoritmos de ensamble, con el objetivo central de identificar la arquitectura con mayor capacidad para capturar patrones temporales complejos y generar estimaciones altamente confiables. Los resultados demuestran que los modelos de ensamble, específicamente con esquema de apilamiento (*Stacking*) y Random Forest como metamodelo, alcanzaron el desempeño superior entre los algoritmos evaluados, logrando un MASE de 0.485. Si bien el análisis sugiere que el modelo captura con precisión las tendencias generales y la estacionalidad, se identificaron limitaciones para anticipar variaciones abruptas vinculadas a factores externos, como variables climatológicas, no integrados en el conjunto de datos actual. No obstante, estos hallazgos evidencian el potencial del modelado predictivo como una herramienta estratégica para la planificación agrícola y la toma de decisiones en el sector agroexportador de Jalisco.

1. Introducción

La producción de alimentos agrícolas representa una de las actividades más importantes dentro de la economía mexicana. De acuerdo con el Censo Agropecuario del INEGI, llevado a cabo en el año 2022, aproximadamente 87.9 millones de hectáreas, equivalentes al 45.9% del territorio nacional, se utilizan para actividades agropecuarias [39], lo que refleja la relevancia de este sector dentro del país.

Sin embargo, llevar a cabo este tipo de actividades requiere de una planeación constante y una adecuada gestión de los recursos para poder aprovechar al máximo la producción generada. Considerando lo anterior, los primeros eslabones dentro de la cadena de valor, específicamente los productores, suelen enfrentar mayores niveles de incertidumbre y riesgo en comparación con otros involucrados. Investigaciones han señalado que, a pesar de ser quienes asumen una gran parte del riesgo productivo, los agricultores no siempre obtienen los mayores beneficios económicos dentro de la cadena, tal como menciona Jorge Esteve del Consejo Nacional Agropecuario [40].

Dentro de los diferentes productos agrícolas que destacan en México, el aguacate se ha consolidado como uno de los cultivos de mayor relevancia económica, tanto por su valor en el mercado nacional como por su participación en exportaciones, siendo el estado de Jalisco uno de los principales actores dentro de la producción de este cultivo.

En este contexto, destaca la Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL), la cual agrupa a diversos productores y actores clave de la cadena de valor del aguacate en la región. Este organismo tiene entre sus objetivos fortalecer la participación y el crecimiento de los distintos integrantes del sector, proporcionando herramientas e información que permitan mejorar la toma de decisiones, la planificación y la comercialización del producto.

Por lo tanto, contar con estimaciones confiables de la oferta futura de aguacate puede representar una herramienta de gran valor para los productores y otros participantes de la cadena, ya que facilita una mejor organización productiva y comercial. Lo anterior es particularmente relevante considerando que los productores suelen ser uno de los eslabones más vulnerables ante las fluctuaciones del mercado y los factores externos que afectan la producción.

A partir de lo anterior, la incorporación de modelos de aprendizaje automático aplicados a series de tiempo representa una alternativa prometedora para generar estimaciones basadas en patrones históricos de producción. El objetivo del presente trabajo es desarrollar y evaluar modelos predictivos capaces de estimar la producción de aguacate en el estado de Jalisco a partir de datos históricos. Para ello se comparan distintos enfoques de modelado, incluyendo modelos estadísticos tradicionales, modelos de aprendizaje automático y modelos de ensamble. El propósito es identificar el modelo con mejor desempeño predictivo y analizar su potencial como herramienta de apoyo para la planificación agrícola y la toma de decisiones en el sector exportador. Dentro del contenido del presente trabajo se presentará la metodología seguida para el modelado, los experimentos realizados, sus resultados y explicaciones del comportamiento detrás de cada experimento.

2. Trabajo Relacionado

La predicción de producción agrícola es un pilar fundamental para la seguridad alimentaria y la toma de decisiones en mercados agroindustriales. Tradicionalmente, se han utilizado modelos estadísticos clásicos como ARIMA. Sin embargo, estos presentan limitaciones significativas cuando las relaciones entre variables son altamente no lineales o existen múltiples factores externos que afectan la serie.

Con el avance del aprendizaje automático, estudios comparativos como los de Shawon et al. y Nigam et al. han demostrado que algoritmos como Random Forest y redes neuronales superan a los modelos lineales tradicionales al capturar interacciones complejas entre variables ambientales y productivas. No obstante, una revisión sistemática exhaustiva realizada por Shawon et al. identifica que, a pesar del éxito del ML en la agricultura de precisión, el rendimiento suele degradarse en escenarios con datos históricos de baja frecuencia o cuando no se consideran adecuadamente las dependencias temporales estrictas.

En el área del aprendizaje profundo, arquitecturas como DeepYield, propuesta por Gavahi et al., han integrado redes convolucionales con LSTM para mejorar el pronóstico mediante sensores remotos. Asimismo, Renukaradya et al. exploraron el uso de LSTM con mecanismos de atención para la estimación de cultivos en regiones específicas de la India. Si bien estos modelos son potentes, trabajos como el de Wang et al. sugieren que los marcos de trabajo puramente geoespaciales o de deep learning masivo pueden ser ineficientes cuando el tamaño del conjunto de datos es limitado, como ocurre con los registros mensuales históricos de la producción de aguacate en Jalisco.

Esta brecha en la literatura, donde los modelos estadísticos son muy simples y los de aprendizaje profundo requieren demasiados datos, hace relevante el presente trabajo. Aquí se propone un enfoque de Ensamble Apilado (Stacking) que combina la robustez de modelos probabilísticos y estadísticos con la flexibilidad no lineal de un metamodelo basado en árboles, logrando un equilibrio óptimo para series temporales de escala moderada, pero con alta estacionalidad.

3. Metodología

El desarrollo del sistema de predicción se llevó a cabo mediante un enfoque estructurado inspirado en metodologías de ciencia de datos como CRISP-ML, el cual permite organizar el proceso de modelado en etapas iterativas que incluyen comprensión del problema, análisis de datos, modelado, evaluación y despliegue del modelo.

El objetivo principal del presente trabajo es construir un modelo capaz de estimar la producción futura de aguacate en el estado de Jalisco a partir de datos históricos de producción.

3.1 Formulación del problema

Sea una serie temporal definida como:

$$y_t = f(t) + \epsilon_t$$

donde:

- y_t representa el valor observado de la producción agrícola en el tiempo t
- $f(t)$ representa la estructura subyacente de la serie (tendencia, estacionalidad o patrones)
- ϵ_t representa el componente aleatorio o ruido

El problema de predicción consiste en estimar los valores futuros de la serie:

$$\hat{y}_{t+h}$$

donde h representa el horizonte de predicción.


En este trabajo se aborda el problema como un problema de regresión supervisada, en el cual el modelo aprende a partir de observaciones históricas para generar estimaciones futuras.

3.2 Análisis exploratorio de datos

Como primera etapa se realizó un análisis exploratorio de la serie temporal de producción de aguacate en el estado de Jalisco, con el objetivo de identificar:

- Tendencias de largo plazo
- Patrones de crecimiento
- Posibles comportamientos estacionales
- Variabilidad de la producción

En el siguiente gráfico podemos observar el comportamiento de los datos recuperados por parte del Servicio de Información Agroalimentaria y Pesquera (SIAP), los cuales, en conjunto con datos complementarios de la U.S. International Trade Commission (USITC), fueron utilizados para realizar una desagregación temporal. Dado que inicialmente la información se encontraba en frecuencia anual.



El análisis permitió observar una tendencia creciente en la producción a lo largo del tiempo, lo cual es consistente con la expansión del cultivo de aguacate en México durante las últimas décadas.

Además, se evaluó la presencia de patrones estacionales y posibles cambios estructurales en la serie, lo cual es relevante para seleccionar los modelos predictivos más adecuados.

3.3 Modelos predictivos evaluados

Con el objetivo de identificar el modelo con mejor desempeño predictivo, se evaluaron distintos enfoques de modelado pertenecientes a tres categorías principales:

Modelos base (baseline)

Se utilizó un modelo Naïve estacional como referencia inicial. Este modelo asume que el valor futuro será igual al valor observado en el mismo periodo del ciclo anterior. Este modelo se mantuvo para poder obtener la métrica MASE, y el modelo de referencia se cambió por *Exponential Smoothing*.

Este tipo de modelo se utiliza comúnmente como punto de comparación para evaluar si los modelos más complejos realmente aportan mejoras significativas en la predicción.

Modelos estadísticos de series temporales

Se evaluaron modelos clásicos utilizados en análisis de series temporales, entre ellos:

- ARIMA
- Prophet
- SARIMAX
- Exponential Smoothing

Estos modelos permiten capturar componentes como tendencia y estacionalidad mediante formulaciones estadísticas explícitas.

Modelos de aprendizaje automático

También se exploraron modelos basados en aprendizaje automático capaces de capturar relaciones no lineales en los datos.

Entre ellos se incluyeron:

- Gaussian Process Regression
- Support Vector Regression

Modelos de aprendizaje profundo

Se evaluaron modelos basados en aprendizaje profundo, los cuales utilizan redes neuronales para aprender representaciones complejas de los datos mediante múltiples capas de procesamiento.

- Long Short-Term Memory
- Multi Layer Perceptron

Las redes LSTM son particularmente adecuadas para el análisis de series temporales debido a su capacidad para capturar dependencias de largo plazo en los datos.

3.4 Modelos de ensamble

Además de los modelos individuales, se exploraron técnicas de ensamble homogéneas y heterogéneas con el objetivo de mejorar el desempeño predictivo.

Las técnicas de ensamble heterogéneas combinan modelos de diferente tipo para capturar distintos patrones en los datos y mejorar la generalización. En este trabajo se evaluaron los siguientes enfoques:

- Simple Averaging Ensemble
- Weighted Average Ensemble
- Stacking Ridge
- Stacking RF

Por otro lado, las técnicas homogéneas utilizan múltiples instancias del mismo modelo base entrenadas sobre distintas muestras del conjunto de datos para reducir la varianza. En este trabajo se exploró:

- Bagging GPR

3.5 Validación y evaluación de modelos

La evaluación de los modelos se realizó mediante una partición temporal fija de proporción 80/20, respetando el orden cronológico de los datos para evitar el uso de información futura durante el entrenamiento. Para la comparación entre modelos se utilizaron múltiples métricas de error.

Definición de métricas de evaluación

Para evaluar el desempeño de los modelos se utilizaron diversas métricas de error comúnmente empleadas en problemas de regresión y pronóstico de series temporales. Estas métricas permiten analizar distintos aspectos del error de predicción y facilitar la comparación entre modelos.

Las métricas seleccionadas incluyen:

- MAE (Error Absoluto Medio)
- RMSE (Error Cuadrático Medio)
- MAPE (Error Porcentual Medio Absoluto)
- R^2 (Coeficiente de determinación)
- MASE (Error de Escala Absoluto Medio)

Estas métricas fueron definidas antes del proceso de entrenamiento de los modelos con el fin de evitar sesgos en la selección del modelo final.

MAE (Error Absoluto Medio)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

El MAE mide el error absoluto promedio entre los valores reales y las predicciones del modelo.

Ventaja: Es fácilmente interpretable, ya que se expresa en las mismas unidades de la variable objetivo.

Uso: Evaluación práctica del error esperado en las predicciones.

RMSE (Error Cuadrático Medio)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

El RMSE calcula la raíz cuadrada del error cuadrático medio, penalizando con mayor severidad los errores grandes.

Ventaja: Es especialmente útil cuando se desea que los errores grandes tengan mayor peso en la evaluación.

Uso: Comparación entre modelos en escenarios donde los valor atípico o desviaciones grandes son relevantes.

MAPE (Error Porcentual Medio Absoluto)

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

El MAPE mide el error absoluto promedio en términos porcentuales.

Ventaja: Es independiente de la escala de la variable, lo que facilita la interpretación del error relativo.

Uso: Evaluación de precisión relativa en contextos productivos o de negocio.

R² (Coeficiente de determinación)

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

El coeficiente de determinación mide la proporción de la varianza de la variable objetivo que es explicada por el modelo.

Ventaja: Permite evaluar la capacidad explicativa del modelo respecto a la variabilidad observada en los datos.

Uso: Métrica complementaria para comparar la calidad general del ajuste entre modelos.

MASE (Error de Escala Absoluto Medio)

$$MASE = \frac{MAE_{\text{modelo}}}{MAE_{\text{naive}}}$$

El MASE escala el error absoluto del modelo con respecto al error de un modelo Naïve de referencia. En este trabajo se utilizó como referencia un modelo Naïve Estacional, el cual predice el valor de una observación utilizando el valor observado en el mismo periodo del ciclo anterior.

El denominador del MASE se calcula exclusivamente sobre el conjunto de entrenamiento, lo que garantiza que la evaluación sobre el conjunto de prueba no incorpore información futura.

Ventaja: Permite comparar modelos de manera justa y evita problemas relacionados con la escala de los datos.

Uso: Benchmarking frente a un modelo base sencillo pero representativo.

Interpretación:

- **MASE < 1:** El modelo es mejor que el modelo base
- **MASE = 1:** Desempeño equivalente al modelo base
- **MASE > 1:** El modelo es peor que el modelo base

Ranking de modelos

Dado que cada métrica de evaluación captura distintos aspectos del error de predicción, la selección del modelo final no se basó únicamente en una sola métrica. En su lugar, se implementó

un mecanismo de ranking multi-criterio que permite comparar el desempeño global de los modelos considerando simultáneamente todas las métricas evaluadas.

El procedimiento seguido fue el siguiente:

1. Cálculo de métricas

Para cada modelo se calcularon las métricas de evaluación sobre el conjunto de prueba: MAE, RMSE, MAPE, R^2 y MASE.

2. Ordenamiento por métrica

Para cada métrica se generó un ranking independiente de los modelos.

- Para MAE, RMSE, MAPE y MASE, un valor menor indica mejor desempeño.
- Para R^2 , un valor mayor indica mejor desempeño.

3. Asignación de posiciones relativas

A cada modelo se le asignó una posición dentro de cada métrica.

La posición 1 corresponde al mejor desempeño dentro de esa métrica.

4. Agregación del ranking

Posteriormente se calculó un puntaje agregado para cada modelo mediante una combinación ponderada de las métricas evaluadas. Para ello, primero se transformaron y normalizaron las métricas con el fin de hacerlas comparables entre sí. Una vez normalizadas, se calculó un puntaje final ponderado para cada modelo:

$$Score_{modelo} = \sum_{k=1}^m w_k \cdot metric_k^{norm}$$

donde:

- es el número de métricas evaluadas
- w_k es el peso asignado a la métrica k
- $metric_k^{norm}$ es el valor normalizado de la métrica k

Finalmente, los modelos se ordenaron de acuerdo con su Score final, donde valores más bajos indican mejor desempeño global.

5. Selección del mejor modelo

El modelo con el menor puntaje agregado se considera el modelo con mejor desempeño global.

Este enfoque permite identificar modelos que presentan un comportamiento consistentemente bueno en múltiples métricas, evitando depender únicamente de una medida específica de error. Métodos de agregación de rankings como este son comunes en problemas de evaluación multi-

criterio dentro del aprendizaje automático y permiten obtener una comparación más robusta entre modelos.

3.6 Selección del modelo final

Con base en el ranking global obtenido, se seleccionó el modelo final para la generación de predicciones. La decisión se sustentó tanto en el desempeño cuantitativo reflejado en las métricas de evaluación como en el comportamiento observado en las gráficas correspondientes al conjunto de prueba.

De esta manera, se priorizó el modelo que presentó el mejor equilibrio entre precisión predictiva y estabilidad a lo largo de la serie temporal. El modelo seleccionado se utilizó posteriormente para generar las predicciones finales y analizar su comportamiento sobre la serie temporal de producción.

4. Experimentación

Esta sección describe el conjunto de datos utilizado, el procedimiento experimental seguido para entrenar y evaluar los modelos, así como las configuraciones de hiperparámetros empleadas durante el proceso de modelado.

4.1 Conjunto de datos

El análisis se realizó utilizando una serie temporal histórica de producción de aguacate en el estado de Jalisco, correspondiente al periodo 1996–2024. La variable objetivo del estudio corresponde al volumen de producción registrado en cada periodo mensual de la serie.

Antes del proceso de modelado se realizó una revisión de calidad de los datos con el fin de identificar valores faltantes, inconsistencias o anomalías que pudieran afectar el entrenamiento de los modelos. Posteriormente, la serie temporal fue organizada cronológicamente para preservar la estructura temporal necesaria para los modelos de pronóstico.

Dado que el objetivo del proyecto es predecir valores futuros de producción, el problema se formuló como un problema de predicción de series temporales univariadas, donde las observaciones pasadas de la serie se utilizan para estimar valores futuros.

4.2 División de datos

Para evaluar adecuadamente el desempeño predictivo de los modelos se dividió la serie temporal en dos subconjuntos:

- Conjunto de entrenamiento (*train*)
Utilizado para entrenar los modelos y ajustar sus parámetros.
- Conjunto de prueba (*test*)
Utilizado exclusivamente para evaluar el desempeño de los modelos en datos no observados durante el entrenamiento.

Debido a la naturaleza temporal del problema, la división se realizó respetando el orden cronológico de los datos, evitando cualquier fuga de información desde el conjunto de prueba hacia el entrenamiento.

La partición temporal fija es ampliamente utilizada en problemas de predicción de series temporales ya que simula escenarios reales de predicción donde únicamente se dispone de información histórica para predecir valores futuros.

4.3 Modelos evaluados

Con el objetivo de comparar distintos enfoques de modelado, se evaluaron modelos pertenecientes a diferentes familias de algoritmos:

Modelo baseline

Se utilizó un modelo *Naïve Estacional* como referencia inicial. Este modelo predice el valor futuro utilizando el valor observado en el mismo periodo del ciclo anterior y sirve como punto de referencia para evaluar si los modelos más complejos aportan mejoras significativas. Este modelo se mantuvo solamente para poder obtener el denominador de la métrica MASE, y como modelo de referencia se utilizó *Exponential Smoothing*, un modelo que captura componentes de tendencia y estacionalidad mediante suavizamiento exponencial. Para este último modelo baseline se le indicó como hiperparámetro un periodo estacional de 12 meses ya que es apropiado para series mensuales con patrón anual, así como se observó en la etapa del análisis exploratorio de datos, y también se le indicó al modelo que se trabajaría con tendencia aditiva y con estacionalidad aditiva.

Modelos estadísticos de series temporales

Se evaluaron modelos clásicos ampliamente utilizados en el análisis de series temporales, entre ellos:

- **ARIMA (AutoRegressive Integrated Moving Average)**
Modelo que combina componentes autorregresivos, diferenciación y media móvil para modelar dependencias temporales en la serie. Como hiperparámetro para el componente autorregresivo se indicó 50, para la diferenciación se especificó 1 y para el promedio móvil 50.
- **SARIMAX (Seasonal ARIMA with eXogenous variables)**
Modelo que extiende ARIMA al incorporar componentes estacionales explícitos y la posibilidad de incluir variables exógenas. Como hiperparámetros del modelo se añadió a las variables independientes del conjunto de entrenamiento como variables exógenas y se especificó el componente estacional de 12 periodos.
- **Prophet**
Modelo desarrollado por Meta que permite modelar series temporales con tendencias no lineales, estacionalidad y efectos de calendario. Como hiperparámetros se especificaron que sí se iba a trabajar con temporalidad anual, que no se iba a trabajar con temporalidad semanal ni diaria, se indicó un valor de 0.05 al parámetro 'changepoint_prior_scale' y un valor de 0.01 al parámetro 'seasonality_prior_scale'.

Modelos de aprendizaje automático

También se exploraron modelos basados en aprendizaje automático que permiten capturar relaciones no lineales en los datos:

- **Support Vector Regression (SVR)**
Modelo que extiende las capacidades de las Máquinas de Vectores de Soporte para problemas de regresión, busca encontrar una función que minimice el error dentro de un margen tolerado. Se utilizaron como hiperparámetros un valor de 100 para 'C', 0.01 para 'epsilon', se especificó que se trabajara con el Kernel RBF y que 'gamma' es 0.001.

- Gaussian Process Regression (GPR)

Modelo que permite estimar funciones continuas y cuantificar incertidumbre en las predicciones. Para este modelo se seleccionó el Kernel *RationalQuadratic* para su entrenamiento, además de que se especificó un valor de 10 al hiperparámetro 'n_restarts_optimizer' y se indicó la semilla 42 para fijar el estado aleatorio del modelo.

Modelos de aprendizaje profundo

Igualmente se exploraron modelos basados en aprendizaje profundo que permiten capturar mayor complejidad en los patrones presentes en los datos:

- Multi Layer Perceptron (MLP)

Una red neuronal artificial de tipo feedforward compuesta por capas ocultas y funciones de activación no lineales. A través del aprendizaje por retropropagación, el modelo ajusta pesos internos para aproximar relaciones complejas entre entradas y salida. La configuración seleccionada para este modelo fue un valor de 100x100 para 'hidden_layer_sizes', 'relu' para 'activation', un valor de 0.0001 para 'alpha' y un 'learning_rate_init' de 0.001, se usó max_iter=1 y warm_start=True para permitir el control manual del entrenamiento época por época conservando los pesos entre iteraciones. Finalmente, se realizó una validación con un split cronológico interno de 80/20 sobre el conjunto de entrenamiento, con un early stopping manual con una patience de 10.

- Long Short-Term Memory (LSTM)

Una red neuronal recurrente diseñada específicamente para modelar dependencias temporales de largo plazo, incorporando celdas de memoria y mecanismos de compuertas que permiten retener o descartar información relevante a lo largo del tiempo. El modelo empleado para el entrenamiento consiste en una capa LSTM con 64 unidades ocultas y una ventana de 12 meses, otra capa Dropout (0.3) para regularización, y una capa densa final con una sola neurona para producir la predicción puntual con una función de activación de tipo 'ReLU'. Adicionalmente, se empleó el optimizador Adam y la función de pérdida de Error Cuadrático Medio (MSE), que son adecuados para problemas de regresión continua. Al igual que también se incorporó Early Stopping con validación interna para prevenir sobreajuste y restaurar los mejores pesos observados durante el entrenamiento. El modelo fue configurado para que fuera entrenado con 100 épocas y con un batch size de 16.

Modelos de ensamble

Además de los modelos individuales, se construyeron varios modelos de ensamble mediante la técnica de apilamiento. En este enfoque, las predicciones generadas por varios modelos base se utilizan como variables de entrada para entrenar un metamodelo que aprende a combinar dichas predicciones. En este trabajo se construyeron los siguientes modelos de ensamble heterogéneos y homogéneos:

- Simple Averaging Ensemble

Combina las predicciones de GPR, SARIMAX, Prophet y MLP calculando el promedio aritmético simple de sus resultados, asignando el mismo peso a cada modelo base.

- **Weighted Average Ensemble**
Extiende el promedio simple asignando pesos distintos a cada modelo base según su desempeño individual. Los pesos asignados fueron 0.70 para GPR, 0.15 para SARIMAX, 0.125 para Prophet y 0.025 para MLP.
- **Stacking Ensemble con Ridge Regression**
Entrena un metamodelo lineal (Ridge Regression) que aprende a combinar las predicciones de GPR, SARIMAX, Prophet y MLP. El parámetro alpha fue optimizado mediante búsqueda exhaustiva (GridSearchCV) con validación cruzada temporal, obteniendo un valor óptimo de 0.001.
- **Stacking Ensemble con Random Forest**
Entrena un metamodelo no lineal (Random Forest) que combina las predicciones de GPR, SARIMAX, Prophet, MLP y SVR, incorporando además features adicionales como estacionalidad cíclica, dispersión entre modelos y un rezago de la variable objetivo. Los hiperparámetros fueron optimizados mediante búsqueda aleatoria (RandomizedSearchCV) con 80 iteraciones y validación cruzada temporal, obteniendo como configuración óptima 500 estimadores, profundidad máxima de 10 y max_features de 0.7.
- **Bagging GPR**
Implementa un ensamble homogéneo entrenando 10 instancias de GPR sobre distintas muestras bootstrap del conjunto de entrenamiento. Cada modelo emplea el Kernel del modelo GPR base con una perturbación gaussiana en sus hiperparámetros (sigma = 0.05) y un optimizador con 10 reinicios. Además de que se especificó una semilla de 42 para definir el estado aleatorio del entrenamiento. La predicción final se obtiene promediando las predicciones individuales de cada instancia.

4.4 Evaluación experimental

Una vez entrenados los modelos, se evaluó su desempeño utilizando el conjunto de prueba. Para ello se calcularon las métricas descritas previamente (MAE, RMSE, MAPE, R^2 y MASE) y también se graficaron sus comportamientos para entender visualmente las diferencias entre los valores reales y los predichos por cada modelo.

Posteriormente se implementó ranking de modelos, que fue descrito en la sección 3.5, con el objetivo de identificar el modelo con mejor desempeño global. Este procedimiento permitió comparar de manera objetiva los distintos enfoques de modelado y seleccionar el modelo final utilizado para generar las predicciones del sistema.

5. Resultados

Tras el entrenamiento y evaluación de los modelos predictivos utilizando el conjunto de prueba cronológico (2019-2024), se identificó al modelo de Apilamiento con *Random Forest (Stacking RF)* como el de mejor desempeño global.

5.1 Análisis de Desempeño Cuantitativo

Para comparar los modelos entrenados se construyó un ranking basado en un score ponderado de métricas normalizadas. Se asignó mayor peso a la métrica MASE del 50% por ser la métrica principal, debido a que esta compara el error del modelo contra el baseline (Naïve), permitiendo interpretar directamente si el modelo mejora el desempeño de una predicción simple.


Métricas adicionales como RMSE y MAE se les asignó 15% respectivamente por capturar la magnitud del error absoluto y cuadrático, mientras que a MAPE y R^2 se les asignó 10% respectivamente por aportar información complementaria sobre error relativo y capacidad explicativa del modelo. Las métricas fueron normalizadas mediante escalamiento Min-Max para hacerlas comparables antes de calcular el score final. El modelo con mejor desempeño será el que esté en el límite inferior (cero) y el de peor rendimiento en el límite superior (uno).

La selección del mejor modelo se fundamentó por medio de este ranking englobando a todos los modelos, donde el *Stacking RF* obtuvo el mejor puntaje. Los resultados clave para este modelo incluyen:

- MASE de 0.485: Indica que el modelo es un 52% más preciso que el baseline Naïve Estacional.
- RMSE de 0.056: Este valor en la escala normalizada demuestra errores consistentes.
- MAE de 0.042: Este valor indica que el modelo se equivoca 0.04 unidades en la escala normalizada del volumen de producción de aguacate.
- R^2 de 0.686: Un valor positivo que confirma la capacidad explicativa del modelo sobre la varianza de la producción, descartando cualquier subajuste.

Comparativamente, los modelos individuales como GPR (MASE 0.493) y SARIMAX (MASE 0.577) mostraron un rendimiento sólido, pero fueron superados por la estrategia de ensamble heterogéneo que permitió corregir sesgos específicos de cada algoritmo base.


En la siguiente imagen se puede apreciar visualmente el orden de exactitud de todos los modelos entrenados basados en el score ponderado de métricas normalizadas.



Para mayor detalle, la siguiente tabla muestra los resultados obtenidos para cada métrica empleada para evaluar cada modelo entrenado, al igual que el tiempo total de entrenamiento.

Modelo	Score	MASE	RMSE	MAE	MAPE	R ²	Tiempo
Stacking RF	0.0000	0.485	0.056	0.042	6.293	0.686	56.529
Stacking Ridge	0.0133	0.493	0.056	0.043	6.411	0.677	1.151
GPR	0.0134	0.493	0.056	0.043	6.411	0.677	10.788
Weighted Average Ensemble	0.0346	0.508	0.057	0.044	6.588	0.663	0.001
Bagging GPR	0.0571	0.521	0.059	0.045	6.788	0.641	96.879
Simple Average Ensemble	0.0846	0.540	0.061	0.047	6.984	0.623	0.001
SARIMAX	0.1389	0.577	0.063	0.050	7.411	0.589	21.287
Prophet	0.1552	0.582	0.066	0.050	7.632	0.557	0.508
MLP	0.1559	0.599	0.065	0.051	7.502	0.562	0.265
SVR	0.2307	0.642	0.067	0.056	8.100	0.541	0.012
LSTM	0.6995	0.924	0.096	0.080	12.597	0.021	5.490
Auto-ARIMA	0.7541	0.946	0.104	0.082	12.786	-0.106	108.205
ARIMA	0.9258	1.064	0.114	0.092	13.198	-0.320	108.205
Exponential Smoothing	1.0000	1.085	0.123	0.094	14.071	-0.549	0.013


Adicionalmente, en el siguiente gráfico se puede observar una comparativa del desempeño de los 5 mejores modelos y el modelo baseline, en donde cada eje corresponde a una métrica de evaluación, y se puede apreciar que el modelo *Stacking RF* nuevamente presenta las métricas más favorables, destacándose por encima del resto de los modelos comparados.




5.2 Análisis Visual y de Residuos

El análisis visual de los resultados del modelo confirma que el modelo captura con éxito la estacionalidad anual, replicando las caídas de producción que ocurren históricamente a mitad de cada año.


Particularmente, el diagnóstico de residuos para el modelo ganador arrojó los siguientes hallazgos:



- La media cercana a cero y la inexistencia de algún patrón claro confirma la ausencia de sesgos sistemáticos de sobreestimación o subestimación, demostrando que el modelo ha capturado en su totalidad la estructura temporal de los datos.




- Se presenta autocorrelación mínima porque los coeficientes en la función de autocorrelación (ACF) se mantienen mayoritariamente dentro de los límites de confianza, indicando que el modelo extrajo casi toda la información estructural de la serie.




- El metamodelo depende prioritariamente de las predicciones de GPR (70% de importancia), utilizando los demás modelos (Prophet, SARIMAX, MLP) para realizar ajustes finos en puntos de alta variabilidad.

Por otro lado, las gráficas de predicción muestran que el modelo de Apilamiento con *Random Forest* logra seguir de manera adecuada la tendencia general de la serie temporal, reproduciendo el crecimiento observado en la producción histórica.



Sin embargo, también se observa que algunos picos o variaciones abruptas no son completamente capturados por el modelo, lo cual sugiere la presencia de factores externos que no están representados en el conjunto de datos utilizado.



6. Discusión

El análisis integral de los experimentos realizados permite fundamentar el éxito del modelo Apilamiento con *Random Forest* y las limitaciones observadas en el resto de las arquitecturas evaluadas.

6.1 Fundamentación del éxito del modelo final

El desempeño superior del *Stacking RF* (MASE 0.485) se debe a su capacidad para integrar fortalezas heterogéneas. El análisis de importancia de variables revela que el metamodelo se apoya en un 70% en las predicciones de GPR. Esto indica que el ensamble utiliza la sólida capacidad probabilística de GPR para capturar la tendencia general, mientras que el *Random Forest* actúa como un refinador no lineal que corrige desviaciones específicas donde otros modelos como SARIMAX o Prophet aportan información complementaria.

6.2 Razones del bajo desempeño en modelos complejos

Contrario a lo esperado inicialmente, modelos de aprendizaje profundo como LSTM no lograron superar significativamente al modelo de referencia. Este fenómeno se atribuye a dos factores principales:

Escalabilidad de datos: El conjunto de datos, aunque abarca un periodo amplio, consta de menos de 300 registros mensuales tras el procesamiento. Las redes neuronales profundas requieren volúmenes masivos de datos para aprender dependencias temporales sin sobreajustarse.

Estructura de la serie: Una parte considerable de la varianza de la producción de aguacate es explicable mediante patrones estacionales simples y tendencias de largo plazo, lo que favorece a modelos estadísticos y de ensamble sobre arquitecturas recurrentes complejas en este volumen de datos.

6.3 Análisis de fallas y picos abruptos

A pesar de su robustez, el modelo ganador presenta dificultades para anticipar caídas o incrementos extremos, como se observa en los picos de error absoluto entre 2022 y 2024. Estas fallas no son deficiencias algorítmicas, sino limitaciones de información:

Variables exógenas ausentes: Factores impredecibles como heladas, estrés hídrico o plagas no están representados en el conjunto de datos actual. Al basarse exclusivamente en el historial de producción, el modelo tiende a suavizar las predicciones hacia la media estacional.

Dependencia de GPR: La dominancia de GPR en el ensamble, si bien aporta estabilidad, puede limitar la adaptabilidad ante cambios estructurales súbitos que no siguen la distribución aprendida previamente.

A manera de síntesis, el modelo funciona eficazmente como un refinador de tendencias históricas, pero su evolución hacia un sistema de alerta temprana requiere la integración futura de variables meteorológicas y eventos de choque.

7. Conclusiones

El presente proyecto cumplió con el objetivo de desarrollar y evaluar un sistema predictivo robusto para estimar la oferta de producción de aguacate en el estado de Jalisco. A través de una metodología rigurosa basada en CRISP-ML, se demostró que el uso de estrategias de ensamble heterogéneo supera la capacidad predictiva de los modelos estadísticos y de aprendizaje automático individuales.

- **Modelo Ganador:** El modelo de Apilamiento con Random Forest (*Stacking RF*) fue seleccionado como la solución final al obtener un MASE de 0.485, lo que representa una mejora del 52% en precisión respecto al modelo base.
- **Capacidad de Generalización:** Los resultados confirman que la arquitectura seleccionada captura adecuadamente la tendencia creciente y los ciclos estacionales característicos del sector agrícola en la región, manteniendo un ajuste consistente en datos no vistos (2019-2024).
- **Eficiencia Operativa:** Con un tiempo de entrenamiento aproximado de 56.52 segundos, el modelo es altamente viable para un entorno de producción, permitiendo reentrenamientos mensuales rápidos y un mantenimiento eficiente bajo principios de MLOps.
- **Limitaciones Identificadas:** Se observó que el desempeño se degrada ante eventos atípicos o choques externos no representados en el conjunto de datos histórico, como fluctuaciones climáticas extremas o plagas.
- **Impacto Estratégico:** Desde una perspectiva aplicada, esta herramienta constituye un insumo valioso para APEAJAL, facilitando la planificación de exportaciones, la gestión logística y la reducción de la incertidumbre en la toma de decisiones comerciales.

Como trabajo futuro, se recomienda la integración de variables exógenas meteorológicas y económicas para fortalecer la capacidad del modelo ante cambios estructurales súbitos. En conclusión, el enfoque de Ensamble Apilado propuesto establece una base sólida para el análisis predictivo avanzado en el sector agroexportador de Jalisco.

Referencias

- [1] Banco de México, 'Sistema de Información Económica (SIE), Cuadro CE37,' Banxico, s.f. Disponible en: <https://www.banxico.org.mx/SieInternet/consultarDirectorioInternetAction.do?sector=1&accion=consultarCuadro&idCuadro=CE37&locale=es>. Accedido: 23-ene.-2026.
- [2] Instituto Nacional de Estadística y Geografía (INEGI), 'Comercio exterior. Datos abiertos,' INEGI, s.f. Disponible en: https://www.inegi.org.mx/programas/comext/#datos_abiertos. Accedido: 23-ene.-2026.
- [3] Instituto Nacional de Estadística y Geografía (INEGI), 'Producto Interno Bruto (PIB). Tabulados,' INEGI, s.f. Disponible en: <https://www.inegi.org.mx/temas/pib/#tabulados>. Accedido: 23-ene.-2026.
- [4] Productores de Aguacate, 'Revista MODULA,' Productores de Aguacate, s.f. Disponible en: <https://www.productoresdeaguacate.com/MODULArevista/modulos/web/www/index.php>. Accedido: 23-ene.-2026.
- [5] Procuraduría Federal del Consumidor (PROFECO), 'Quién es Quién en los Precios. Datos abiertos,' PROFECO, s.f. Disponible en: https://datos.profeco.gob.mx/datos_abiertos/qqp.php. Accedido: 23-ene.-2026.
- [6] Secretaría de Agricultura y Desarrollo Rural, 'Cierre agrícola,' AGRICULTURA, s.f. Disponible en: https://nube.agricultura.gob.mx/cierre_agricola/. Accedido: 23-ene.-2026.
- [7] Secretaría de Agricultura y Desarrollo Rural, 'Datos abiertos del sector agrícola,' AGRICULTURA, s.f. Disponible en: <https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>. Accedido: 23-ene.-2026.
- [8] Servicio Nacional de Sanidad, Inocuidad y Calidad Agroalimentaria (SENASICA), 'Estadística de producción de aguacate,' SIAS, s.f. Disponible en: <https://dj.senasica.gob.mx/sias/Statistics/Transversal/EstadisticaProduccionAguacate>. Accedido: 23-ene.-2026.
- [9] United States International Trade Commission (USITC), 'DataWeb: Importaciones generales por HTS,' USITC, s.f. Disponible en: <https://dataweb.usitc.gov/trade/search/GenImp/HTS>. Accedido: 28-ene.-2026.
- [10] S. Galli, Python Feature Engineering Cookbook, 2nd ed., Packt Publishing, 2022.
- [11] Towards Data Science, 'Codificación cíclica,' s.f. Disponible en: <https://towardsdatascience.com/cyclical-encoding-an-alternative-to-one-hot-encoding-for-time-series-features-4db46248ebba/>. Accedido: 7-feb.-2026.
- [12] R. J. Hyndman y G. Athanasopoulos, 'Series de Fourier,' OTexts, s.f. Disponible en: <https://otexts.com/fpp3/useful-predictors.html#fourier-series>. Accedido: 7-feb.-2026.
- [13] Regresión lineal con Scikit-Learn, LEARN STATISTICS EASILY, 13-feb.-2024.
- [14] Regresión Ridge (Scikit-learn), CDS Institute, 13-sep.-2025.
- [15] Lasso (Scikit-learn), CDS Institute, 13-sep.-2025.
- [16] Naïve forecasting, Llamasoft, s.f.
- [17] 'How to interpret ARIMA(0,1,0),' Cross Validated, 27-oct.-2017.
- [18] 'ARIMA forecast with python statsmodels,' Stack Overflow, s.f.
- [19] Arize, 'R-squared — Understanding the coefficient of determination,' 2023.
- [20] A. Smith, 'The foundation of model evaluation,' Medium, 2023.
- [21] T. R. Alper, 'Introduction to Gaussian Process Regression Part 1,' Medium, 2020.
- [22] A. Damianou y N. Lawrence, 'Deep Gaussian Processes,' arXiv, 2020.
- [23] GeeksforGeeks, 'Gaussian Process Regression (GPR),' s.f.
- [24] Data Science Collective, 'Future Forecasting of Time Series Using LSTM,' Medium, 2020.
- [25] J. Brownlee, Mastering Time Series Forecasting, Machine Learning Mastery, 2020.
- [26] Z. Smith, 'Advances in Time Series Forecasting,' arXiv, 2024.
- [27] S. Olumide, 'How to Implement ARIMA Modeling in Python,' Statology, 13-may.-2025.
- [28] A. Williams, 'Python Statsmodels SARIMAX,' PY Tutorial, 21-ene.-2025.
- [29] scikit-learn, 'MLPRegressor documentación,' 2026.
- [30] scikit-learn, 'SVR documentación,' 2026.
- [31] TecMNA2025MLOpsEq25, "mna-mlops-sep2025-eq25," GitHub repository, 2025. Disponible en: <https://github.com/TecMNA2025MLOpsEq25/mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.
- [32] Equipo 25, "servicio-mna-mlops-sep2025-eq25," DockerHub repository, 2025. Disponible en: <https://hub.docker.com/r/jplopezs/servicio-mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.
- [33] S. M. Shawon et al., "A Comparative Study of Agricultural Crop Yield Prediction Using Machine Learning," IEEE Xplore, 2023. [En línea]. Disponible en: <https://ieeexplore.ieee.org/abstract/document/10112854>
- [34] A. Nigam, S. Garg, A. Agrawal, P. Agrawal et al., "Crop Yield Prediction Using Machine Learning Algorithms," IEEE Xplore, 2019. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/8985951>
- [35] K. Gavahi, P. Abbaszadeh y H. Moradkhani, "DeepYield: A combined convolutional neural network with long short-term memory for crop yield forecasting," Expert Systems with Applications, vol. 184, p. 115511, 2021. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0957417421009210>
- [36] S. M. Shawon, F. B. Ema, A. K. Mahi, F. L. Niha y H. T. Zubair, "Crop yield prediction using machine learning: An extensive and systematic literature review," Smart Agricultural Technology, vol. 10, 100718, 2025. [En línea]. Disponible en: <https://doi.org/10.1016/j.atech.2024.100718>
- [37] L. Wang, Z. Chen, W. Liu y H. Huang, "A Temporal-Geospatial Deep Learning Framework for Crop Yield Prediction," Electronics, vol. 13, no. 21, p. 4273, 2024. [En línea]. Disponible en: <https://www.mdpi.com/2079-9292/13/21/4273>

- [38] N. G. Renukaradya, K. G. Rao y A. B. Jayachandra, "Classification and Estimation of Crop Yield Prediction in Karnataka using LSTM with Attention Mechanism," *International Journal of Intelligent Systems and Applications in Engineering*, vol. 12, no. 3, 2024. [En línea]. Disponible en: <https://ijisae.org/index.php/IJISAE/article/view/5226>
- [39] Forbes Staff, "Costos, clima e inseguridad, principales problemas de agricultores mexicanos," *Forbes México*, 21 nov. 2023. [En línea]. Disponible en: <https://forbes.com.mx/costos-clima-e-inseguridad-principales-problemas-de-agricultores-mexicanos/> Accedido: 15-mar-2026
- [40] Redacción Tierras, "El campo mexicano ahonda su crisis de rentabilidad y deja sin sembrar el 20% de la superficie agrícola," *Interempresas*, 15 dic. 2025. [En línea]. Disponible en: <https://www.interempresas.net/Grandes-cultivos/617172-campo-mexicano-ahonda-crisis-rentabilidad-deja-sin-sembrar-20-por-ciento-superficie.html> Accedido: 15-mar-2026