



Modelo Predictivo de la Oferta de Producción de Aguacate en Jalisco

Asociación de Productores Exportadores de Aguacate de Jalisco

Resumen Ejecutivo (Rúbrica Original)

Profesores

Titular: Dra. Grettel Barceló Alonso
Titular: Dr. Luis Eduardo Falcón Morales

Asesor

Dr. Gerardo Jesús Camacho González

Patrocinadores

Dr. Jorge Antonio Ascencio Gutiérrez
Yanmei King Loeza

Equipo 29

Carolina Lucas Dophe – [A01702450](#)
Juan Pablo López Sánchez – [A01313663](#)
Víctor Hugo Soto Herrera – [A01706446](#)

Tabla de Contenido

INTRODUCCIÓN	3
1. SÍNTESIS DEL PROBLEMA	4
1.1 CONTEXTO DEL SECTOR AGUACATERO EN JALISCO	4
1.2 PROBLEMÁTICA IDENTIFICADA	5
1.3 JUSTIFICACIÓN DE LA SOLUCIÓN	5
2. HALLAZGOS MÁS IMPORTANTES DEL ANÁLISIS EXPLORATORIO DE DATOS	7
2.1 DESCRIPCIÓN DEL CONJUNTO DE DATOS	7
2.2 TENDENCIAS Y ESTACIONALIDAD IDENTIFICADAS	8
2.3 ANOMALÍAS Y EVENTOS ATÍPICOS	9
2.4 IMPLICACIONES PARA EL MODELADO PREDICTIVO	9
3. MODELOS GENERADOS Y MODELO FINAL	10
3.1 SÍNTESIS DE LA METODOLOGÍA DEL MODELADO	10
3.2 MODELO FINAL SELECCIONADO	11
4. RECOMENDACIONES CLAVE PARA IMPLEMENTAR LA SOLUCIÓN	13
5. ANÁLISIS DE COSTOS Y BENEFICIOS	14
5.1 COSTOS DEL PROYECTO POR FASE CRISP-ML	14
5.2 COSTOS DE INFRAESTRUCTURA PARA DESPLIEGUE	14
5.3 COSTOS DE OPERACIÓN Y MANTENIMIENTO DEL MODELO	15
5.4 ESTIMACIÓN DE COSTOS OPERATIVOS	15
5.5 BENEFICIOS POTENCIALES DEL SISTEMA	17
6. RIESGOS Y DESAFÍOS DE LA SOLUCIÓN	18
6.1 RIESGOS ASOCIADOS A LOS DATOS	18
6.2 ATAQUES AI/ML	19
6.3 PRUEBAS Y CONFIANZA	19
6.4 CUMPLIMIENTO	19
7. CONCLUSIÓN EJECUTIVA	20
REFERENCIAS	22

Introducción

La producción de alimentos agrícolas representa una de las actividades más importantes dentro de la economía mexicana. De acuerdo con el Censo Agropecuario del INEGI, llevado a cabo en el año 2022, aproximadamente 87.9 millones de hectáreas, equivalentes al 45.9% del territorio nacional, se utilizan para actividades agropecuarias [33], lo que refleja la relevancia de este sector dentro del país.

Sin embargo, llevar a cabo este tipo de actividades requiere de una planeación constante y una adecuada gestión de los recursos para poder aprovechar al máximo la producción generada. Al mismo tiempo, el sector agrícola enfrenta diversos retos asociados a factores externos como condiciones climáticas, variaciones en los mercados, costos de producción e incluso temas de seguridad, los cuales pueden impactar directamente los resultados obtenidos por los productores.

Considerando lo anterior, los primeros eslabones dentro de la cadena de valor, específicamente los productores, suelen enfrentar mayores niveles de incertidumbre y riesgo en comparación con otros involucrados. Investigaciones han señalado que, a pesar de ser quienes asumen una gran parte del riesgo productivo, los agricultores no siempre obtienen los mayores beneficios económicos dentro de la cadena, tal como menciona Jorge Esteve del Consejo Nacional Agropecuario [34].

Dentro de los diferentes productos agrícolas que destacan en México, el aguacate se ha consolidado como uno de los cultivos de mayor relevancia económica, tanto por su valor en el mercado nacional como por su participación en exportaciones, siendo el estado de Jalisco uno de los principales actores dentro de la producción de este cultivo.

En este contexto, destaca la Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL), la cual agrupa a diversos productores y actores clave de la cadena de valor del aguacate en la región. Este organismo tiene entre sus objetivos fortalecer la participación y el crecimiento de los distintos integrantes del sector, proporcionando herramientas e información que permitan mejorar la toma de decisiones, la planificación y la comercialización del producto.

Por lo tanto, contar con estimaciones confiables de la oferta futura de aguacate puede representar una herramienta de gran valor para los productores y otros participantes de la cadena, ya que facilita una mejor organización productiva y comercial. Lo anterior es particularmente relevante considerando que los productores suelen ser uno de los eslabones más vulnerables ante las fluctuaciones del mercado y los factores externos que afectan la producción.

A partir de lo anterior, la incorporación de modelos de aprendizaje automático aplicados a series de tiempo representa una alternativa prometedora para generar estimaciones basadas en patrones históricos de producción. En el presente trabajo se presenta una síntesis de los principales resultados obtenidos a lo largo del proyecto, incluyendo la definición del problema, los hallazgos del análisis exploratorio de datos, la construcción y evaluación de modelos predictivos, así como recomendaciones para la posible implementación de la solución, su análisis costo beneficio y los riesgos asociados, con el objetivo de ofrecer una visión clara y concisa del valor que este tipo de herramientas puede aportar como apoyo en la toma de decisiones dentro del sector.

1. Síntesis del Problema

La falta de certeza para la toma de decisiones relacionadas con la producción y cosecha de aguacate se identifica como uno de los principales desafíos dentro del sector. Esta situación genera diversas consecuencias que impactan directamente a los productores, quienes suelen verse afectados, debido a que enfrentan de manera directa los efectos de la incertidumbre en la producción y en el comportamiento del mercado.

Contar con una herramienta que permita generar estimaciones más confiables sobre la oferta futura del producto puede contribuir a fortalecer la planeación productiva y la gestión de la oferta, proporcionando un mayor respaldo en la toma de decisiones. Esto representa una oportunidad para mejorar la organización dentro de la cadena de valor del aguacate, considerando que se trata de un sector que enfrenta retos provenientes de distintos ámbitos.

En la siguiente sección se explorará con mayor detalle el contexto actual del sector aguacatero en Jalisco, con el fin de identificar el punto de partida del análisis. Posteriormente se presentará la problemática identificada y finalmente, la justificación de la solución propuesta dentro de este proyecto.

1.1 Contexto del sector aguacatero en Jalisco

Como ya se ha venido comentando, los productores agrícolas enfrentan múltiples desafíos que impactan directamente su actividad. Para evidenciar esto, de acuerdo con datos del Censo Agropecuario 2022 del INEGI, 9 de cada 10 productores, es decir, el 88.8%, reportaron como principal problema los altos costos de insumos y servicios, mientras que 61% señaló pérdidas ocasionadas por factores climáticos o biológicos, y 22.8% mencionó la inseguridad como una de sus principales preocupaciones [33]. Estas estadísticas evidencian los retos que enfrenta el sector agrícola a nivel nacional.

En el caso específico del sector aguacatero en Jalisco, su impacto económico dentro del país ha ido en constante crecimiento. Actualmente Jalisco ocupa el segundo lugar nacional en producción de aguacate, solo por detrás de Michoacán, de acuerdo con información del Servicio de Información Agroalimentaria y Pesquera (SIAP).

Este crecimiento también se ha visto reflejado en la expansión de la superficie cultivada. En los últimos años, la industria del aguacate en el estado ha crecido aproximadamente 40%, pasando de alrededor de 22 mil hectáreas sembradas en 2021 a cerca de 37 mil hectáreas en 2023, con una producción estimada cercana a 94 mil toneladas anuales [35].

Parte de este crecimiento se debe al desarrollo de huertas jóvenes que recientemente han comenzado a entrar en producción, así como al enfoque en mejorar las condiciones técnicas y productivas de las plantaciones existentes. Tal como lo indicó Eleazar Ocegüera Aguayo, representante de la asociación de productores, en 2023 muchas de las huertas establecidas en

años recientes continúan desarrollándose, lo que contribuye al incremento gradual de la producción [35].

A lo anterior se suman condiciones climatológicas favorables en la región, así como el interés por impulsar el crecimiento de esta industria debido a su potencial económico y de exportación.

En este contexto, organizaciones como la Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL) juegan un papel importante al apoyar a los productores en procesos de organización y acceso a mercados, contribuyendo así a fortalecer la cadena productiva del aguacate en la región.

1.2 Problemática identificada

Después de presentar el contexto general del sector aguacatero en Jalisco, es posible abordar la problemática principal que se busca atender dentro de APEAJAL. Uno de los retos más relevantes identificados tanto para la asociación como para los productores es la incertidumbre en la estimación de la oferta productiva de aguacate en el estado de Jalisco. Esta situación dificulta la planeación productiva y la toma de decisiones por parte de los productores, así como de otros actores que participan dentro de la cadena de valor.

La oferta de aguacate presenta variaciones significativas a lo largo del tiempo, influenciadas por factores climatológicos, productivos propios del cultivo y económicos. Estas fluctuaciones generan incertidumbre dentro del sector, ya que actualmente no siempre se cuenta con herramientas analíticas que permitan anticipar estos cambios de manera sistemática.

Ante este escenario, surge la necesidad de modelar y anticipar el comportamiento de la oferta productiva, generando información predictiva que pueda apoyar los procesos de planeación dentro de la cadena de valor del aguacate. Contar con este tipo de herramientas puede representar un apoyo importante para los productores y al mismo tiempo contribuir a fortalecer el crecimiento de la industria aguacatera en Jalisco, permitiendo mejorar la toma de decisiones y apoyar a los distintos actores que participan en la producción y comercialización del producto.

1.3 Justificación de la solución

Después de presentar el contexto del sector y la problemática identificada, queda clara la necesidad de desarrollar una herramienta analítica que permita estimar la oferta productiva del aguacate en el estado de Jalisco. Por ello, se propone el desarrollo de un modelo predictivo basado en técnicas de aprendizaje automático que utilice datos históricos y variables explicativas relevantes para generar estimaciones de la producción futura.

El objetivo de este modelo es generar predicciones que puedan servir como soporte para la planeación de la producción y el análisis de escenarios dentro de la cadena de valor del aguacate. Contar con este tipo de información permitiría reducir parte de la incertidumbre que enfrentan los productores y otros actores del sector al momento de tomar decisiones relacionadas con la producción, comercialización y gestión de la oferta.

La viabilidad del desarrollo de esta solución se basa en la disponibilidad de datos históricos proporcionados por instituciones y organizaciones vinculadas al sector, así como en el interés de distintos actores involucrados en el proyecto, entre los que se encuentran los estudiantes responsables del desarrollo técnico y analítico, profesores e investigadores que brindan acompañamiento académico, asesores técnicos y de dominio que aportan conocimiento especializado sobre el sector aguacatero y la APEAJAL que participa como entidad colaboradora y caso de estudio, facilitando el acceso a información relevante y conocimiento del contexto productivo.

Aunque el modelo desarrollado no será implementado en un entorno productivo durante el transcurso del proyecto, los resultados obtenidos permitirán evaluar su utilidad potencial y analizar su viabilidad para una posible implementación futura. De esta manera, el proyecto busca sentar las bases para el desarrollo de herramientas analíticas que contribuyan a mejorar la planeación y la toma de decisiones dentro del sector aguacatero en Jalisco.

2. Hallazgos más Importantes del Análisis Exploratorio de Datos

Una vez identificado el problema y la solución analítica propuesta, se realizó un análisis exploratorio de los datos con el objetivo de comprender la estructura de la información disponible, así como identificar tendencias, patrones y posibles comportamientos relevantes dentro del conjunto de datos. Este proceso permitió obtener un primer entendimiento del comportamiento histórico de la oferta productiva de aguacate y de las variables asociadas al fenómeno de estudio.

En las siguientes subsecciones se presentan los hallazgos más relevantes del análisis exploratorio, incluyendo la descripción del conjunto de datos, las tendencias y estacionalidades identificadas, la presencia de anomalías o eventos atípicos, así como las principales implicaciones que estos resultados tienen para el desarrollo de los modelos predictivos.

2.1 Descripción del conjunto de datos

Como parte del análisis exploratorio, se realizó una revisión inicial de las fuentes de información disponibles con el objetivo de comprender la estructura, alcance y calidad de los datos que servirían como base para el modelado predictivo.

La principal fuente de información utilizada corresponde a datos oficiales publicados por el Servicio de Información Agroalimentaria y Pesquera (SIAP), los cuales contienen estadísticas históricas sobre la producción agrícola en México. A partir de esta fuente se recopiló información relacionada con el cultivo de aguacate en el estado de Jalisco, incluyendo variables productivas como superficie sembrada, superficie cosechada, volumen de producción y modalidad de producción.

Debido a que se integraron distintas bases de datos provenientes del SIAP que presentan diferencias en su nivel de desagregación geográfica, se filtraron únicamente los registros correspondientes al cultivo de aguacate en Jalisco. Como resultado, se obtuvo un conjunto de datos históricos que abarca el periodo de 1980 a 2024, lo que permitió construir una serie temporal para analizar el comportamiento de la producción de aguacate en el estado.

Dado que la información productiva se encontraba disponible principalmente con frecuencia anual, se emplearon datos complementarios provenientes de la U.S. International Trade Commission (USITC) con el objetivo de capturar la distribución temporal mensual del comportamiento del mercado. Este indicador se utilizó como referencia para estimar la distribución relativa de la producción a lo largo del año, permitiendo construir una serie temporal de mayor granularidad que facilitara el análisis de patrones temporales y estacionalidad.

Finalmente, se realizaron ajustes en la estructura del conjunto de datos para garantizar que cada periodo temporal contara con un único registro agregado de producción, aspecto necesario para el uso de modelos de series de tiempo. Como resultado de este proceso se obtuvo un conjunto de datos consistente que integra información histórica relevante para el análisis del comportamiento productivo del aguacate en Jalisco.

2.2 Tendencias y estacionalidad identificadas

A partir del análisis exploratorio de la serie temporal construida, se identificaron distintos patrones relevantes en el comportamiento histórico de la producción de aguacate en Jalisco.

En primer lugar, se observa una tendencia creciente en la producción a lo largo del tiempo, particularmente a partir de finales del año 2000. Este comportamiento indica un crecimiento en la actividad productiva en la región, lo cual es consistente con el aumento que ha experimentado la industria del aguacate en México durante las últimas décadas.




Fig. 1. Producción histórica de 1996 a 2024

Adicionalmente, la serie presenta patrones de estacionalidad, reflejados en fluctuaciones recurrentes dentro de cada año. Estas variaciones responden a los ciclos naturales de producción agrícola, así como a factores climáticos y de manejo del cultivo que influyen en los periodos de mayor y menor disponibilidad del producto. De igual forma, se identifican variaciones en la magnitud de la producción, lo que sugiere posibles afectaciones por factores externos como condiciones climáticas extremas, cambios en la superficie cultivada o variaciones en la demanda del mercado.

Como parte del proceso de ingeniería de características previo al modelado, algunas variables fueron escaladas para mantener una escala homogénea dentro del conjunto de datos. Por esta razón, la serie presentada en la gráfica se encuentra normalizada en un rango de 0 a 1, lo cual permite analizar los patrones temporales sin alterar la forma original de la distribución de los datos.

En conjunto, estos resultados evidencian que la serie presenta componentes de tendencia y estacionalidad, características típicas de los datos de producción agrícola y fundamentales para el desarrollo de modelos de predicción basados en series de tiempo.

2.3 Anomalías y eventos atípicos

Durante el análisis exploratorio del conjunto de datos se evaluó la presencia de anomalías que pudieran afectar el proceso de modelado. En primer lugar, se verificó que el dataset no presenta valores faltantes, lo cual permitió trabajar directamente con los registros disponibles sin necesidad de aplicar técnicas de imputación.

Posteriormente, se analizaron posibles valores atípicos en las variables numéricas mediante diagramas de caja. A partir de este análisis se observó que las variables Sembrada, Cosechada y Volumenproduccion presentaban algunos valores extremos en comparación con la distribución general de los datos. Estos valores fueron revisados y depurados con el objetivo de reducir la influencia de observaciones extremas que pudieran afectar el comportamiento del modelo.

Adicionalmente, se llevó a cabo un proceso de selección y depuración de variables, eliminando aquellas que no aportaban información relevante para el modelado o que podían generar redundancias. Entre las variables descartadas se incluyen variables monetarias, variables derivadas de otras métricas productivas y variables administrativas utilizadas durante la construcción del dataset, así como aquellas que no presentaban variación en los datos.

En conjunto, este proceso permitió obtener un conjunto de datos más consistente y adecuado para el desarrollo de modelos de predicción.

2.4 Implicaciones para el modelado predictivo

A partir del análisis exploratorio realizado, se identificaron algunas conclusiones relevantes que deberán considerarse para el desarrollo de los modelos. En primer lugar, el conjunto de datos presenta una extensión limitada en términos de observaciones y variables disponibles, lo que puede restringir la complejidad de los modelos que pueden aplicarse y la capacidad de capturar patrones más complejos en la serie.

Adicionalmente, debido al proceso de desagregación temporal utilizado para construir la serie mensual, parte de la información original puede presentar cierto nivel de aproximación. Por esta razón, los modelos desarrollados deben interpretarse como herramientas de apoyo para el análisis y la toma de decisiones, más que como mecanismos únicos o definitivos de predicción.

No obstante, los patrones identificados durante el análisis exploratorio, como la tendencia creciente y la presencia de estacionalidad, proporcionan una base adecuada para la aplicación de técnicas de modelado de series de tiempo orientadas a la estimación de la producción futura.

3. Modelos Generados y Modelo Final

Conociendo ahora un poco más la naturaleza y la consistencia de los datos con los que se están trabajando, además del tipo de solución que se busca implementar para resolver la problemática planteada, es necesario proceder con la implementación de diversos modelos de aprendizaje automático. Para ello es importante tener definido un plan de trabajo que permita realizar diversos experimentos que evidencien claramente el rendimiento de modelos y su utilidad para la resolución del problema planteado.

En la siguiente sección se describirá dicho plan de trabajo de forma sintetizada, visibilizando el proceso que se siguió en este trabajo y las consideraciones que se tuvieron para optimizar los resultados. Posteriormente, se explicará y justificará el modelo final seleccionado que encaja de mejor manera con la solución esperada para este problema.

3.1 Síntesis de la metodología del modelado

El enfoque empleado para el desarrollo del modelo predictivo fue sobre aprendizaje automático supervisado aplicado a series de tiempo, esto debido a la naturaleza del problema que se está trabajando. El proceso que se siguió a grandes rasgos fue la preparación de los datos, el entrenamiento de múltiples modelos de aprendizaje automático y la evaluación comparativa de su desempeño.

En primera instancia, se realizó la integración y limpieza de los datos provenientes de distintas fuentes de información relacionadas con la producción agrícola, superficie cultivada y otras variables relevantes para el cultivo de aguacate en Jalisco. Posteriormente, se aplicaron técnicas de preprocesamiento y transformación de variables, como lo fueron el manejo de valores faltantes, estandarización y generación de variables derivadas. De esta forma, se garantiza la construcción de un conjunto de datos que sea de calidad al reflejar con mayor precisión la realidad, y que a su vez tenga información de utilidad.

Teniendo listo el conjunto de datos, se procedió a emplearlos para el entrenamiento de diversos modelos de aprendizaje automático, con el fin de comparar su capacidad predictiva. Este proceso de evaluación comparativa permite identificar el algoritmo que mejor aprende y se ajusta a los patrones presentes en los datos. En el ámbito del aprendizaje automático, es una práctica común el evaluar múltiples modelos para seleccionar aquel que presenta el mejor equilibrio entre exactitud y capacidad de generalización.

Para abordar el problema adecuadamente, se incluyeron diversos enfoques en el modelado. Se implementaron los modelos estadísticos clásicos de series de tiempo *Exponential Smoothing*, *ARIMA*, *SARIMAX* y *Prophet*. También se implementaron los modelos basados en aprendizaje automático *Support Vector Regression (SVR)* y *Gaussian Process Regression (GPR)*. Igualmente se implementaron los modelos de redes neuronales *Multilayer Perceptron (MLP)* y *Long Short-Term Memory (LSTM)*. Por último, se implementaron los modelos de ensamble *Promedio Simple*,

Promedio Ponderado, Apilamiento con Ridge Regression, Apilamiento con Random Forest y Bagging con GPR.

Finalmente, los modelos fueron evaluados utilizando métricas de desempeño apropiadas para problemas de regresión y series de tiempo, destacando principalmente la métrica del error cuadrático medio (RMSE) y el error absoluto medio (MAE). Permitiendo así medir directamente la diferencia entre los valores reales observados y las predicciones generadas por cada modelo. De esta forma se puede comparar objetivamente distintos algoritmos para seleccionar aquel que ofrece mejores resultados en términos de exactitud y estabilidad. Adicionalmente, como punto de referencia, se utilizó como modelo baseline al modelo *Exponential Smoothing* y un modelo *Naïve*, que ayudó para establecer un desempeño mínimo esperado para los demás modelos, y asegurar que modelos más complejos sean significativamente mejores que los simples.

3.2 Modelo final seleccionado

Como resultado de la metodología previamente presentada, se seleccionó como modelo final el *Apilamiento con Random Forest*, por presentar el mejor rendimiento a comparación del resto de modelos. Primeramente, el modelo supera en buena medida al modelo baseline. Para poder cuantificar esta medición se empleó la métrica MASE, en la cual el modelo final obtuvo 0.48, indicando entonces que el error del modelo final es 52% menor que el del modelo baseline. Esta medición es relevante porque demuestra que la complejidad del modelo final sí aporta valor para realizar predicciones más confiables.

En cuanto a las métricas empleadas para evaluar el modelo final, este es el que obtuvo el RMSE más bajo de todos los modelos, teniendo un error típico de aproximadamente 0.05 en la escala normalizada de volumen de producción de aguacate. Igualmente, el modelo final fue el que obtuvo el menor MAE de los modelos, donde en promedio el modelo se equivoca 0.04 unidades en la escala normalizada del volumen de producción de aguacate, es decir un 4% del rango total. Como la métrica obtenida del RMSE es muy similar a la de MAE, entonces se puede saber que los errores del modelo son bastantes consistentes y no hay errores grandes ocasionales.

Para entender visualmente el comportamiento del modelo final, se puede observar en el siguiente gráfico la comparación entre datos reales del conjunto de validación y las predicciones realizadas por el modelo.




Fig. 2. Valores Reales vs predicción (Stacking RF)

Como resultado de entrenar el modelo con registros desde 1996 hasta 2018, se puede observar que el modelo logró aprender adecuadamente para poder realizar predicciones que se acerquen a los valores reales desde 2019 hasta 2025. Específicamente, en esta gráfica, se puede ver que el modelo final logra capturar la estacionalidad de los datos, ya que parece repetir el mismo patrón que se presenta cada año; en los datos reales se puede observar que a mitad de cada año hay siempre una caída en el volumen de producción de aguacate, y el modelo logra replicar tal comportamiento.

Con base en las métricas y el comportamiento presentado del modelo, es que se puede confirmar que el modelo final seleccionado está listo para ser implementado en producción. El modelo construido es lo suficientemente robusto para realizar predicciones con un grado de confianza aceptable sobre el volumen de producción de aguacate en el estado de Jalisco de forma mensual, siendo de utilidad como insumo para la planeación productiva y el análisis de escenarios futuros.

Adicionalmente, el tiempo de entrenamiento del modelo final seleccionado es reducido, ya que tarda tan solo poco menos de un minuto, exactamente 56.52 segundos, y proporciona los mejores resultados. Esta duración en el entrenamiento del modelo es muy importante porque indica que el modelo tiene una gran facilidad de mantenimiento, lo cual lo vuelve muy eficiente para poder ser reentrenado y reajustado cuando se necesite.

4. Recomendaciones Clave para Implementar la Solución

A partir de los resultados obtenidos, se recomienda implementar el modelo predictivo como una herramienta de apoyo analítico para la estimación de la oferta futura de producción de aguacate en el estado de Jalisco. El objetivo principal no es reemplazar el conocimiento experto del sector, sino complementarlo mediante estimaciones basadas en el comportamiento histórico de los datos.

En primer lugar, se sugiere realizar una fase inicial de implementación piloto, en la cual el modelo sea desplegado en un entorno controlado dentro de la infraestructura tecnológica existente de la organización. En esta etapa, el modelo puede integrarse mediante una API de predicción que permita generar estimaciones bajo demanda a partir de los datos más recientes disponibles. Este enfoque permite validar la utilidad práctica del sistema y evaluar su desempeño en un contexto operativo real sin incurrir en costos elevados de infraestructura.

Posteriormente, una vez validada la funcionalidad del sistema y su utilidad para los procesos de análisis interno, se recomienda considerar una segunda fase de despliegue en la nube, utilizando servicios administrados que faciliten la escalabilidad, disponibilidad y mantenimiento del modelo. En este proyecto se identificó a Google Cloud Platform como una opción adecuada debido a la facilidad de despliegue de contenedores mediante servicios serverless y su integración con herramientas modernas de MLOps.

Adicionalmente, se recomienda establecer mecanismos de monitoreo continuo del desempeño del modelo, así como un proceso periódico de reentrenamiento con nuevos datos para evitar degradación en la calidad de las predicciones. Estos procesos permitirán mantener la utilidad del sistema en el tiempo conforme evolucionen las condiciones productivas del sector.

Finalmente, para mejorar el potencial predictivo del modelo, se sugiere incorporar en futuras iteraciones variables exógenas relevantes, tales como condiciones climáticas, presencia de plagas, cambios en la demanda internacional o variaciones en políticas comerciales. La integración de este tipo de información podría aumentar significativamente la capacidad del modelo para capturar cambios abruptos en la producción.

5. Análisis de Costos y Beneficios

El análisis costo–beneficio del proyecto considera tanto los costos asociados al desarrollo del modelo como los costos esperados para su implementación y operación. Para estructurar este análisis se utiliza la metodología CRISP-ML, identificando los recursos requeridos en cada fase del ciclo de vida del proyecto.

Asimismo, se evalúan dos escenarios posibles para el despliegue del sistema:

1. Infraestructura local (On-Premise) para fases iniciales de validación.
2. Infraestructura en la nube (Google Cloud Platform) para un escenario de escalamiento y disponibilidad operativa.

5.1 Costos del proyecto por fase CRISP-ML

Los costos del proyecto pueden agruparse de acuerdo con las etapas principales del desarrollo de soluciones de aprendizaje automático. Se omite la última fase (Monitoreo y Mantenimiento) dado que el modelo aún no está desplegado.

Fase CRISP-ML	Costos Asociados
Comprensión del negocio y de los datos	Tiempo de analistas y científicos de datos para definir el problema, identificar fuentes de información y comprender las variables relevantes para el modelado.
Adquisición y preparación de datos	Obtención y limpieza de datos históricos de producción agrícola, preparación de series temporales y generación de variables derivadas necesarias para el entrenamiento de los modelos.
Modelado y experimentación	Uso de recursos de cómputo para entrenamiento de modelos, ejecución de experimentos, validación cruzada y optimización de hiperparámetros.
Evaluación del modelo	Análisis de métricas de desempeño, generación de visualizaciones, validación de resultados y documentación técnica del modelo.
Preparación para despliegue	Desarrollo de componentes de integración, generación de API de predicción, contenedorización del modelo y diseño de la arquitectura de implementación.

En el contexto de este proyecto académico, la mayor parte de los costos corresponde al tiempo de trabajo del equipo de desarrollo, así como al uso de recursos computacionales de propósito general.

5.2 Costos de infraestructura para despliegue

Para la implementación operativa del modelo se consideran dos escenarios tecnológicos.

Escenarios	Costos Principales
Servidor Propio (On-Premise)	Tiempo de analistas y científicos de datos para definir el problema, identificar fuentes de información y comprender las variables relevantes para el modelado.
Google Cloud Platform (GCP)	Obtención y limpieza de datos históricos de producción agrícola, preparación de series temporales y generación de variables derivadas necesarias para el entrenamiento de los modelos.

El enfoque *On-Premise* permite realizar pruebas iniciales y validaciones internas con costos reducidos, mientras que el uso de plataformas en la nube ofrece ventajas significativas en términos de escalabilidad, disponibilidad y facilidad de mantenimiento.

5.3 Costos de operación y mantenimiento del modelo

Una vez implementado el sistema, se espera incurrir en ciertos costos recurrentes asociados con su operación continua:

- Mantenimiento de la infraestructura tecnológica.
- Monitoreo del desempeño del modelo.
- Actualización periódica de los datos.
- Reentrenamiento del modelo conforme se disponga de nueva información.
- Soporte técnico y administración del sistema.

Estos costos suelen ser relativamente moderados en comparación con los costos iniciales de desarrollo, especialmente cuando se utilizan servicios administrados en la nube.

5.4 Estimación de costos operativos

Dado que el modelo ya se encuentra desarrollado, los costos asociados a su implementación se concentran principalmente en operación, monitoreo y mantenimiento del sistema. Para estimar estos costos se consideran dos escenarios de implementación: infraestructura local (*On-Premise*) y despliegue en la nube mediante Google Cloud Platform (GCP).

Escenario 1: Infraestructura local (*On-Premise*)

En este escenario se asume que la organización ya dispone de un servidor o infraestructura tecnológica básica donde el modelo pueda ejecutarse. Por lo tanto, los costos principales corresponden al mantenimiento del sistema y al tiempo del personal encargado de su operación.

Concepto	Costos Estimado Anual (USD)
Mantenimiento del servidor	\$300 - \$600
Energía eléctrica y red	\$150 - \$300
Monitoreo del modelo (tiempo del analista)	\$1,000 - \$2,000

Actualización y reentrenamiento del modelo	\$1,000 - \$2,000
---	-------------------

Costo total estimado anual (USD): \$2,450 - \$4,900

Este escenario resulta adecuado cuando el sistema se utiliza principalmente para análisis internos o consultas ocasionales, ya que permite operar el modelo con costos relativamente bajos.

Escenario 2: Despliegue en la nube (Google Cloud Platform)

En un escenario de mayor disponibilidad o uso externo del sistema, el modelo puede desplegarse utilizando servicios administrados en la nube, como Cloud Run o Vertex AI. Estos servicios permiten ejecutar el modelo en contenedores con escalamiento automático según la demanda.

Concepto	Costos Estimado Anual (USD)
Cloud Run (bajo tráfico)	\$60 - \$240
Almacenamiento de datos	\$30 - \$120
Monitoreo y logs	\$60 - \$180
Reentrenamiento del modelo	\$120 - \$360

Costo total estimado anual (USD): \$270 - \$900

Sin embargo, estos costos pueden aumentar si el número de solicitudes al sistema crece significativamente.

Comparación de escenarios

Escenario	Ventajas	Desventajas
On-Premise	Control total sobre la infraestructura, adecuado para pruebas internas y bajo tráfico	Escalabilidad limitada y mayor responsabilidad de mantenimiento
GCP	Escalabilidad automática, alta disponibilidad, menor mantenimiento técnico	Costos variables según uso

En el caso de un sistema con bajo volumen de solicitudes, los beneficios de una infraestructura en la nube podrían no justificar completamente los costos asociados, por lo que una implementación inicial en infraestructura local podría resultar más eficiente.

Por el contrario, si el sistema evoluciona hacia un servicio de consulta frecuente o acceso público, el uso de plataformas en la nube se vuelve más conveniente debido a su capacidad de escalamiento automático.

5.5 Beneficios potenciales del sistema

La implementación de un sistema predictivo para estimar la producción de aguacate puede aportar diversos beneficios estratégicos para organizaciones del sector agrícola y exportador.

Entre los beneficios potenciales se encuentran:

- Mejor planeación de la oferta agrícola, mediante estimaciones preliminares de producción futura.
- Apoyo analítico para la toma de decisiones, complementando la experiencia de especialistas del sector.
- Mayor visibilidad de tendencias productivas, facilitando el análisis de comportamiento del mercado.
- Optimización de procesos de planeación de exportaciones, logística y comercialización.
- Base tecnológica para el desarrollo de sistemas analíticos más avanzados, incluyendo modelos que integren variables climáticas, económicas o de mercado.

En este sentido, el valor principal del sistema no reside en la precisión del modelo, sino en su capacidad para transformar datos históricos en información útil para la toma de decisiones estratégicas.

6. Riesgos y Desafíos de la Solución

A pesar de la robustez, de los beneficios y utilidades del modelo final seleccionado, existen riesgos que deben ser contemplados para que pueda tomarse acción inmediata y evitar que el modelo deje de ser útil. En las próximas secciones se comentarán dichos riesgos y su impacto sobre el desempeño del modelo.

6.1 Riesgos asociados a los datos

Uno de los principales riesgos de este modelo seleccionado son las variables externas no consideradas. El modelo propuesto no toma en cuenta variables climatológicas, por lo que eventos esporádicos como una helada o un estrés hídrico, que lleguen a afectar la producción de aguacate, no podrán ser contemplados en las predicciones realizadas. El modelo tampoco contempla eventos de choque, por lo que cualquier accidente relacionado con la maquinaria agrícola que llegue a causar cambios en la planeación productiva o genere atrasos en algún proceso, entonces no será considerado por el modelo.

De la misma forma, el modelo no considera el estado de salud de los cultivos. No se tiene alguna variable que refleje la existencia de alguna plaga que provoque el deterioro de los cultivos, derivando en la pérdida de cierta cantidad de aguacates o ralentizando el proceso de producción. Igualmente, el modelo está limitado a únicamente considerar el mercado de aguacate en Jalisco, por lo que fluctuaciones en la demanda internacional de aguacate que provoquen cambios en el volumen de producción nacional no será contemplado.

Igualmente, otro riesgo importante del modelo son los cambios estructurales en la producción. Decisiones en la política internacional o incluso nacional que afecten a los productores para seguir con sus procesos habituales para la producción de aguacate pueden cambiar el comportamiento histórico de los datos. Además, por su naturaleza esporádica y formato no estructurado, esta información no puede ser directamente implementada como variable para el modelo.

Otro riesgo que es muy importante considerar son los datos faltantes en la nueva adquisición de registros para los datos históricos. Eventualmente será necesario reentrenar el modelo para que pueda adaptarse a los nuevos patrones presentes en fechas recientes cuando se detecte una deficiencia significativa en la exactitud de las predicciones, por lo que será importante reentrenar el modelo con los nuevos datos capturados. En esto último será muy importante que los nuevos datos se encuentren completos, o por lo menos la mayoría ya que, de lo contrario, si hay muchos meses sin registros de producción o con valores estimados, entonces el modelo puede aprender patrones incorrectos y realizar predicciones imprecisas.

Un riesgo que también es necesario contemplar, y que va relacionado con el riesgo previamente discutido, es que las mediciones realizadas y que serán registradas e incluidas en el dataset histórico del modelo deben ser registros correctos, o por lo menos caer dentro de un margen de error aceptable, ya que el incluir observaciones incorrectas en reportes agrícolas o bases públicas puede introducir ruido y empeorar la exactitud del modelo.

6.2 Ataques AI/ML

El modelo seleccionado tiene un riesgo alto de envenenamiento de los datos de entrenamiento. Como el modelo está empleando fuentes públicas para la construcción de un dataset robusto, estas fuentes pueden ser fácilmente manipuladas al no provenir de fuentes privadas que generalmente tienen mayor seguridad para evitar manipulación de terceros no autorizados. Esto representa un riesgo ya que el modelo podría aprender patrones incorrectos, y por lo tanto las predicciones realizadas no serían de utilidad por el distanciamiento que tendrían con la realidad.

Otro riesgo que si bien, para este caso no está presente, pero si se llegara a trabajar con un dataset que proviniera de fuentes privadas, entonces el modelo tendría el riesgo de que se realice una inversión del modelo, en donde un atacante podría intentar reconstruir información del dataset original a partir del modelo, lo cual puede llegar a representar un ataque a la privacidad de los datos si se expusiera el volumen de producción de aguacate de organizaciones privadas.

6.3 Pruebas y confianza

Como se mencionó anteriormente, el modelo está sesgado a solo funcionar cuando no se presentan sequías, plagas, cambios de política agrícola o cualquier otro evento extremo. No obstante, como trabajo futuro, está planeado la integración de variables climatológicas, eventos de choque y costos de producción; así como el aumento del tamaño del dataset y posiblemente el cambio de frecuencia de registro a una más recurrente con el fin de contar una mayor cantidad de registros para mejorar la resolución y la exactitud del modelo.

Otro riesgo existente en el modelo es que como justamente es un modelo de ensamble, entonces es más complicado explicar el razonamiento de la predicción para ciertos valores. Lo que a nivel técnico complica la validación de la lógica que sigue el modelo para realizar predicciones, lo cual puede generar menos confianza para los tomadores de decisiones ya que les impide evaluar los factores individuales que provocan el resultado, funcionando más bien como una caja negra.

6.4 Cumplimiento

Si bien el modelo emplea datos públicos, entonces no existen riesgos en cuanto a regulación. Sin embargo, en cuanto al uso responsable, el modelo tiene el riesgo de impactar en decisiones económicas, por lo que errores en predicciones podrían afectar a productores, cadenas de suministro e incluso precios del mercado. Por ello es que la mitigación de la mayoría de los riesgos previamente explicados para garantizar la calidad de los datos y seguridad del modelo es sumamente importante para obtener predicciones confiables.

Finalmente, como se explicó previamente que el modelo no es fácilmente interpretable, esto puede representar otro riesgo ya que existen ciertos contextos institucionales que puedan exigir la explicabilidad de los resultados.

7. Conclusión Ejecutiva

El presente trabajo tuvo como objetivo desarrollar y evaluar modelos predictivos para estimar la producción de aguacate en el estado de Jalisco mediante técnicas de análisis de series temporales y aprendizaje automático. A partir de datos históricos de producción agrícola, se exploraron distintos enfoques de modelado, incluyendo modelos estadísticos tradicionales, modelos de aprendizaje automático y modelos de ensamble.

Los resultados obtenidos muestran que los modelos de ensamble pueden ofrecer mejoras en el desempeño predictivo respecto a los modelos individuales. En particular, el modelo de Apilamiento con Random Forest como metamodelo logró el mejor desempeño global entre los algoritmos evaluados, obteniendo las mejores posiciones en el ranking multi-métrica construido a partir de MAE, RMSE, MAPE, R^2 y MASE. Este resultado sugiere que la combinación de diferentes modelos base permite capturar de manera más efectiva los patrones presentes en la serie temporal de producción.

El análisis visual de las predicciones indica que el modelo seleccionado es capaz de reproducir adecuadamente la tendencia general de crecimiento observada en la serie histórica, lo que confirma su utilidad para generar estimaciones basadas en el comportamiento pasado de la producción. No obstante, también se observó que algunos cambios abruptos en la serie no son capturados completamente por el modelo, lo cual sugiere que existen factores externos relevantes que no están representados en los datos disponibles.

Entre estos factores se encuentran variables como condiciones climáticas, plagas, cambios en la superficie cultivada, variaciones en la demanda internacional o decisiones de política comercial. La ausencia de este tipo de variables limita la capacidad del modelo para anticipar fluctuaciones inesperadas en la producción.

Asimismo, los resultados del estudio evidencian que modelos más complejos no necesariamente garantizan un mejor desempeño predictivo, especialmente cuando el tamaño del conjunto de datos es relativamente limitado. En este contexto, algunos modelos avanzados como las redes neuronales LSTM no lograron superar consistentemente a enfoques más simples o a modelos basados en ensambles.

Desde una perspectiva aplicada, el modelo desarrollado puede considerarse una herramienta de apoyo analítico para la estimación de producción agrícola, proporcionando proyecciones que pueden complementar el análisis realizado por expertos del sector. Este tipo de herramientas puede contribuir a mejorar procesos de planificación productiva, estimación de oferta exportable y análisis estratégico dentro de organizaciones vinculadas al sector aguacatero.

Para su implementación en un entorno operativo, es recomendable complementar el modelo con una infraestructura de monitoreo y reentrenamiento periódico, que permita detectar posibles degradaciones en el desempeño del modelo a lo largo del tiempo. En este sentido, el presente trabajo también propone un entorno conceptual de producción que incluye componentes de

versionado de datos, seguimiento de experimentos, monitoreo de desempeño y automatización del reentrenamiento del modelo.

Como líneas de trabajo futuro, se sugiere explorar la incorporación de variables exógenas relevantes, tales como información climática, indicadores económicos o datos geoespaciales relacionados con la superficie cultivada. Asimismo, podría evaluarse el uso de modelos híbridos que integren información temporal y espacial para mejorar la capacidad predictiva del sistema.

En conjunto, este estudio demuestra el potencial de las técnicas de aprendizaje automático y modelos de ensamble para apoyar el análisis predictivo en el sector agrícola, particularmente en contextos donde la disponibilidad de datos históricos permite identificar patrones relevantes en la producción.

En conclusión, el uso de modelos de aprendizaje automático aplicados al análisis de series temporales agrícolas representa una herramienta prometedora para apoyar la toma de decisiones en el sector agroexportador, particularmente cuando se integran dentro de infraestructuras de datos que permitan su actualización y monitoreo continuo.

Referencias

- [1] Banco de México, 'Sistema de Información Económica (SIE), Cuadro CE37,' Banxico, s.f. Disponible en: <https://www.banxico.org.mx/SieInternet/consultarDirectorioInternetAction.do?sector=1&accion=consultarCuadro&idCuadro=CE37&locale=es>. Accedido: 23-ene.-2026.
- [2] Instituto Nacional de Estadística y Geografía (INEGI), 'Comercio exterior. Datos abiertos,' INEGI, s.f. Disponible en: https://www.inegi.org.mx/programas/comext/#datos_abiertos. Accedido: 23-ene.-2026.
- [3] Instituto Nacional de Estadística y Geografía (INEGI), 'Producto Interno Bruto (PIB). Tabulados,' INEGI, s.f. Disponible en: <https://www.inegi.org.mx/temas/pib/#tabulados>. Accedido: 23-ene.-2026.
- [4] Productores de Aguacate, 'Revista MODULA,' Productores de Aguacate, s.f. Disponible en: <https://www.productoresdeaguacate.com/MODULArevista/modulos/web/www/index.php>. Accedido: 23-ene.-2026.
- [5] Procuraduría Federal del Consumidor (PROFECO), 'Quién es Quién en los Precios. Datos abiertos,' PROFECO, s.f. Disponible en: https://datos.profeco.gob.mx/datos_abiertos/qqp.php. Accedido: 23-ene.-2026.
- [6] Secretaría de Agricultura y Desarrollo Rural, 'Cierre agrícola,' AGRICULTURA, s.f. Disponible en: https://nube.agricultura.gob.mx/cierre_agricola/. Accedido: 23-ene.-2026.
- [7] Secretaría de Agricultura y Desarrollo Rural, 'Datos abiertos del sector agrícola,' AGRICULTURA, s.f. Disponible en: <https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>. Accedido: 23-ene.-2026.
- [8] Servicio Nacional de Sanidad, Inocuidad y Calidad Agroalimentaria (SENASICA), 'Estadística de producción de aguacate,' SIAS, s.f. Disponible en: <https://dj.senasica.gob.mx/sias/Statistics/Transversal/EstadisticaProduccionAguacate>. Accedido: 23-ene.-2026.
- [9] United States International Trade Commission (USITC), 'DataWeb: Importaciones generales por HTS,' USITC, s.f. Disponible en: <https://dataweb.usitc.gov/trade/search/GenImp/HTS>. Accedido: 28-ene.-2026.
- [10] S. Galli, Python Feature Engineering Cookbook, 2nd ed., Packt Publishing, 2022.
- [11] Towards Data Science, 'Codificación cíclica,' s.f. Disponible en: <https://towardsdatascience.com/cyclical-encoding-an-alternative-to-one-hot-encoding-for-time-series-features-4db46248ebba/>. Accedido: 7-feb.-2026.
- [12] R. J. Hyndman y G. Athanasopoulos, 'Series de Fourier,' OTexts, s.f. Disponible en: <https://otexts.com/fpp3/useful-predictors.html#fourier-series>. Accedido: 7-feb.-2026.
- [13] Regresión lineal con Scikit-Learn, LEARN STATISTICS EASILY, 13-feb.-2024.
- [14] Regresión Ridge (Scikit-learn), CDS Institute, 13-sep.-2025.
- [15] Lasso (Scikit-learn), CDS Institute, 13-sep.-2025.
- [16] Naïve forecasting, Llamasoft, s.f.
- [17] 'How to interpret ARIMA(0,1,0),' Cross Validated, 27-oct.-2017.
- [18] 'ARIMA forecast with python statsmodels,' Stack Overflow, s.f.
- [19] Arize, 'R-squared — Understanding the coefficient of determination,' 2023.
- [20] A. Smith, 'The foundation of model evaluation,' Medium, 2023.
- [21] T. R. Alper, 'Introduction to Gaussian Process Regression Part 1,' Medium, 2020.
- [22] A. Damianou y N. Lawrence, 'Deep Gaussian Processes,' arXiv, 2020.
- [23] GeeksforGeeks, 'Gaussian Process Regression (GPR),' s.f.
- [24] Data Science Collective, 'Future Forecasting of Time Series Using LSTM,' Medium, 2020.
- [25] J. Brownlee, Mastering Time Series Forecasting, Machine Learning Mastery, 2020.
- [26] Z. Smith, 'Advances in Time Series Forecasting,' arXiv, 2024.
- [27] S. Olumide, 'How to Implement ARIMA Modeling in Python,' Statology, 13-may.-2025.
- [28] A. Williams, 'Python Statsmodels SARIMAX,' PY Tutorial, 21-ene.-2025.
- [29] scikit-learn, 'MLPRegressor documentación,' 2026.
- [30] scikit-learn, 'SVR documentación,' 2026.
- [31] TecMNA2025MLOpsEq25, "mna-mlops-sep2025-eq25," GitHub repository, 2025. Disponible en: <https://github.com/TecMNA2025MLOpsEq25/mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.
- [32] Equipo 25, "servicio-mna-mlops-sep2025-eq25," DockerHub repository, 2025. Disponible en: <https://hub.docker.com/r/jplopezs/servicio-mna-mlops-sep2025-eq25>. Accedido: 05-mar.-2026.
- [33] Forbes Staff, "Costos, clima e inseguridad, principales problemas de agricultores mexicanos," Forbes México, 21 nov. 2023. [En línea]. Disponible en: <https://forbes.com.mx/costos-clima-e-inseguridad-principales-problemas-de-agricultores-mexicanos/>. Accedido: 15-mar-2026.
- [34] Redacción Tierras, "El campo mexicano ahonda su crisis de rentabilidad y deja sin sembrar el 20% de la superficie agrícola," Interempresas, 15 dic. 2025. [En línea]. Disponible en: <https://www.interempresas.net/Grandes-cultivos/617172-campo-mexicano-ahonda-crisis-rentabilidad-deja-sin-sembrar-20-por-ciento-superficie.html>. Accedido: 15-mar-2026.
- [35] R. Hurtado, "Jalisco aumenta 40% hectáreas para aguacate," Milenio, 31 jul. 2023. [En línea]. Disponible en: <https://www.milenio.com/politica/comunidad/jalisco-aumenta-40-hectareas-para-aguacate>. Accedido: 15-mar-2026.
- [36] Asociación de Productores Exportadores de Aguacate de Jalisco (APEAJAL), "¿Quiénes somos?," APEAJAL. [En línea]. Disponible en: <https://apeajal.com/quienes-somos/>. Accedido: 15-mar-2026.
- [37] Secretaría de Agricultura y Desarrollo Rural, "Producción agrícola," Gobierno de México. [En línea]. Disponible en: <https://www.gob.mx/agricultura/dgsiap/acciones-y-programas/produccion-agricola-404122>. Accedido: 15-mar-2026.