

Modelado predictivo de la oferta de producción de aguacate en el estado de Jalisco

Asociación de Productores Exportadores de Aguacate de Jalisco, A. C.

Presenta(n):

- Juan Pablo López Sánchez - A01313663
- Víctor Hugo Soto Herrera - A01706446
- Carolina Lucas Dophe - A01702450

Asesor:

- Dr. Gerardo Jesús Camacho González

Patrocinador(es):

- Dr. Jorge Antonio Ascencio Gutiérrez
- Yanmei King Loeza

Jueves 19 de marzo de 2026

Problemática

La producción agrícola es difícil de anticipar

- Actualmente muchas decisiones se basan principalmente en **experiencia histórica y estimaciones manuales**.
- La producción de aguacate presenta **variaciones significativas a lo largo del tiempo**.
- Las decisiones del sector exportador dependen de **estimaciones confiables de oferta futura**.



Gobierno de Jalisco, "Imagen," 2023. [Online]. Available: https://jalisco.gob.mx/sites/default/files/img_5487.jpeg

¿Podemos utilizar datos históricos para generar estimaciones de producción más informadas mediante modelos predictivos?

Datos Utilizados

Datos históricos


- Datos Abiertos SIAP (anuales)
 - Producción estatal de aguacate
- Importaciones mensuales (USITC)
 - Proxy de demanda internacional

Período analizado

- Datos originales: 1980 – 2024
- Conjunto final: 1996 – 2024
 - Por consistencia temporal

Desagregación temporal

- Método Denton proporcional
- Serie indicadora: importaciones
- Salida: serie mensual consistente




Hallazgos del Análisis Exploratorio

Principales patrones identificados:

- Tendencia creciente en la producción.
- Estacionalidad clara a lo largo de los años.
- Variaciones interanuales significativas.
- Comportamiento influenciado por posibles

factores externos.

- Condiciones climáticas
- Nutrientes del suelo
- Costo de insumos
- Eventos de choque
- Plagas



juan-pablo-lopez. "Imagen," 2026. [Online]. Disponible:
<https://github.com/juan-pablo-lopez/tc5035-ene26-equipo29/tree/main>


Modelos Evaluados

Modelos Base

- Exponential Smoothing
- ARIMA
- **SARIMAX** 
- SVR 
- **GPR** 
- **MLP** 
- LSTM
- **Prophet** 

Modelos de Ensamble

- Promedio Simple
- Promedio Ponderado
- Apilamiento con Ridge Regression
- Apilamiento con Random Forest
- Bagging con GPR



Métricas

Modelo	Score Final	MASE	RMSE	MAE	MAPE	R ²	Tiempo de Entrenamiento
Stacking_RF	0.000000	0.485131	0.055500	0.042013	6.293113	0.685612	68.777885
Stacking_Ridge	0.013378	0.493838	0.056277	0.042767	6.410628	0.676752	1.708098
GPR	0.013454	0.493892	0.056280	0.042772	6.411228	0.676714	13.288453
Weighted Average Ensemble	0.034600	0.507803	0.057488	0.043977	6.587789	0.662687	0.001007
Bagging_GPR	0.057173	0.520923	0.059310	0.045113	6.787613	0.640964	105.348744
Simple Averaging Ensemble	0.084615	0.539649	0.060757	0.046734	6.983877	0.623238	0.001618
SARIMAX	0.138951	0.576657	0.063460	0.049939	7.411434	0.588960	25.938121
Prophet	0.155296	0.581693	0.065914	0.050376	7.631575	0.556562	1.071931
MLP	0.159847	0.590079	0.065470	0.051102	7.502625	0.562511	0.388280
SVR	0.230771	0.642383	0.067041	0.055631	8.099991	0.541263	0.014081
LSTM	0.470703	0.785741	0.085130	0.068046	9.579802	0.225296	11.413721
Auto-ARIMA	0.754144	0.945814	0.104104	0.081909	12.785917	-0.106143	120.941615
ARIMA	0.925889	1.063822	0.113730	0.092129	13.198084	-0.320164	120.941615
Exponential Smoothing	1.000000	1.085431	0.123189	0.094000	14.070841	-0.548907	0.016154

Solución Propuesta

Stacking Ensemble + Random Forest


Desempeño predictivo

Resultados principales:

- Mejora respecto a modelos individuales.
- Buen ajuste a la tendencia histórica.
- Capacidad para capturar patrones generales.

Limitación:

- Menor capacidad para anticipar **eventos abruptos o extraordinarios**.



juan-pablo-lopez. "Imagen," 2026. [Online]. Available:
<https://github.com/juan-pablo-lopez/tc5035-ene26-equipo29/tree/main>

Utilidad para la APEAJAL

Aplicaciones reales

El modelo puede utilizarse para:

- generar estimaciones preliminares de producción
- analizar tendencias
- planeación de exportaciones
- soporte analítico para decisiones estratégicas



El modelo complementa la experiencia humana con análisis basado en datos.

Implementación Propuesta


Arquitectura sugerida

Componentes:

- API de predicción
- contenedor Docker
- monitoreo del modelo
- reentrenamiento periódico

Infraestructura:

- fase inicial: **servidor local**
- escalamiento: **Google Cloud Platform**



juan-pablo-lopez. "Imagen," 2026. [Online]. Disponible:
<https://github.com/juan-pablo-lopez/tc5035-ene26-equipo29/tree/main>

Beneficios Esperados

Valor para la organización

- ✓ mejor visibilidad de tendencias productivas
- ✓ apoyo analítico para decisiones estratégicas
- ✓ base para futuros sistemas predictivos
- ✓ integración con herramientas de análisis de datos




Convertir datos históricos en información útil para la toma de decisiones.

Trabajo Futuro

Oportunidades de mejora

Próximos pasos:


- Incorporar variables externas:
 - Eventos climáticos (pasados y pronosticados)
 - Plagas
 - Costos de insumos
 - Nutrientes disponibles en la tierra
 - Eventos de choque
- Aumentar el tamaño del dataset
- Monitorear continuamente del modelo



Conclusión

- Los modelos de ensamble mejoraron el desempeño predictivo.
- El modelo seleccionado capaz de seguir tendencias.
- Puede implementarse como **herramienta de apoyo para la toma de decisiones**.

El análisis predictivo puede convertirse en un activo estratégico para el sector agroexportador.



juan-pablo-lopez. "Imagen," 2026. [Online]. Disponible:
<https://github.com/juan-pablo-lopez/tc5035-ene26-equipo29/tree/main>

¡Gracias!

Preguntas

Referencias

- [1] Banco de México, 'Sistema de Información Económica (SIE), Cuadro CE37,' Banxico, s.f. Disponible en: <https://www.banxico.org.mx/SielInternet/consultarDirectorioInternetActividades.do?sector=1&accion=consultarCuadro&idCuadro=CE37&locale=es>. Accedido: 23-ene.-2026
- [2] Instituto Nacional de Estadística y Geografía (INEGI), 'Comercio exterior. Datos abiertos,' INEGI, s.f. Disponible en: https://www.inegi.org.mx/programas/comext/#datos_abiertos. Accedido: 23-ene.-2026. (PIB).
- [3] Instituto Nacional de Estadística y Geografía (INEGI), 'Producto Interno Bruto Tabulados,' INEGI, s.f. Disponible en: <https://www.inegi.org.mx/temas/pib/#tabulados>. Accedido: 23-ene. 2026.
- [4] Productores de Aguacate, 'Revista MODULA,' Productores de Aguacate, s.f. Disponible en: <https://www.productoresdeaguacate.com/MODULArevista/modulos/web/www/index.php>. Accedido: 23-ene.-2026.
- [5] Procuraduría Federal del Consumidor (PROFECO), 'Quién es Quién en los Precios. Datos abiertos,' PROFECO, s.f. Disponible en: https://datos.profeco.gob.mx/datos_abiertos/qqp.php. Accedido: 23-ene. 2026.
- [6] Secretaría de Agricultura y Desarrollo Rural, 'Cierre agrícola,' AGRICULTURA, s.f. Disponible https://nube.agricultura.gob.mx/cierre_agricola/. en: Accedido: 23-ene. 2026.
- [7] Secretaría de Agricultura y Desarrollo Rural, 'Datos abiertos del sector agrícola,' AGRICULTURA, s.f. Disponible en: <https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>. Accedido: 23-ene.-2026.
- [8] Servicio Nacional de Sanidad, Inocuidad y Calidad Agroalimentaria (SENASICA), 'Estadística de producción de aguacate,' SIAS, s.f. Disponible en: <https://dj.senasica.gob.mx/sias/Statistics/Transversal/EstadisticaProduccionAguacate>. Accedido: 23-ene.-2026.
- [9] United States International Trade Commission (USITC), 'DataWeb: Importaciones generales por HTS,' USITC, s.f. Disponible en: <https://dataweb.usitc.gov/trade/search/GenImp/HTS>. Accedido: 28-ene. 2026.
- [10] S. Galli, Python Feature Engineering Cookbook, 2nd ed., Packt Publishing, 2022.
- [11] Towards Data Science, 'Codificación cíclica,' s.f. Disponible en: <https://towardsdatascience.com/cyclical-encoding-an-alternative-to-one-hot-encoding-for-time-series-features-4db46248ebba/>. Accedido: 7-feb. 2026.
- [12] R. J. Hyndman y G. Athanasopoulos, 'Series de Fourier,' OTexts, s.f. Disponible en: <https://otexts.com/fpp3/useful-predictors.html#fourier-series>. Accedido: 7-feb.-2026
- [13] Regresión lineal con Scikit-Learn, LEARN STATISTICS EASILY, 13 feb.-2024.
- [14] Regresión Ridge (Scikit-learn), CDS Institute, 13-sep.-2025.
- [15] Lasso (Scikit-learn), CDS Institute, 13-sep.-2025.
- [16] Naïve forecasting, Llamasoft, s.f.
- [17] 'How to interpret ARIMA(0,1,0),' Cross Validated, 27-oct.-2017.
- [18] 'ARIMA forecast with python statsmodels,' Stack Overflow, s.f.

Referencias

- [19] Arize, 'R-squared — Understanding the coefficient of determination,' 2023.
- [20] A. Smith, 'The foundation of model evaluation,' Medium, 2023.
- [21] T. R. Alper, 'Introduction to Gaussian Process Regression Part 1,' Medium, 2020.
- [22] A. Damianou y N. Lawrence, 'Deep Gaussian Processes,' arXiv, 2020.
- [23] GeeksforGeeks, 'Gaussian Process Regression (GPR),' s.f.
- [24] Data Science Collective, 'Future Forecasting of Time Series Using LSTM,' Medium, 2020.
- [25] J. Brownlee, Mastering Time Series Forecasting, Machine Learning Mastery, 2020.
- [26] Z. Smith, 'Advances in Time Series Forecasting,' arXiv, 2024.
- [27] S. Olumide, 'How to Implement ARIMA Modeling in Python,' Statology, 13-may.-2025.
- [28] A. Williams, 'Python Statsmodels SARIMAX,' PY Tutorial, 21-ene. 2025.
- [29] scikit-learn, 'MLPRegressor documentación,' 2026.
- [30] scikit-learn, 'SVR documentación,' 2026.
- [31] TecMNA2025MLOpsEq25, "mna-mlops-sep2025-eq25," repository, 2025. Disponible GitHub en: <https://github.com/TecMNA2025MLOpsEq25/mna-mlops-sep2025-eq25> eq25. Accedido: 05-mar.-2026.
- [32] Equipo 25, "servicio-mna-mlops-sep2025-eq25," DockerHub repository, 2025. Disponible en: <https://hub.docker.com/r/jplopezs/servicio-mna-mlops-sep2025-eq25> mlops-sep2025-eq25. Accedido: 05-mar.-2026.
- [33] S. M. Shawon et al., "A Comparative Study of Agricultural Crop Yield Prediction Using Machine Learning," IEEE Xplore, 2023. [En línea]. Disponible en: <https://ieeexplore.ieee.org/abstract/document/10112854>
- [34] A. Nigam, S. Garg, A. Agrawal, P. Agrawal et al., "Crop Yield Prediction Using Machine Learning Algorithms," IEEE Xplore, 2019. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/8985951>
- [35] K. Gavahi, P. Abbaszadeh y H. Moradkhani, "DeepYield: A combined convolutional neural network with long short-term memory for crop yield forecasting," Expert Systems with Applications, vol. 184, p. 115511, 2021. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0957417421009210>
- [36] S. M. Shawon, F. B. Ema, A. K. Mahi, F. L. Niha y H. T. Zubair, "Crop yield prediction using machine learning: An extensive and systematic literature review," Smart Agricultural Technology, vol. 10, 100718, 2025. [En línea]. Disponible en: <https://doi.org/10.1016/j.atech.2024.100718>
- [37] L. Wang, Z. Chen, W. Liu y H. Huang, "A Temporal–Geospatial Deep Learning Framework for Crop Yield Prediction," Electronics, vol. 13, no. 21, p. 4273, 2024. [En línea]. Disponible en: <https://www.mdpi.com/2079-9292/13/21/4273>
- [38] N. G. Renukaradya, K. G. Rao y A. B. Jayachandra, "Classification and Estimation of Crop Yield Prediction in Karnataka using LSTM with Attention Mechanism," International Journal of Intelligent Systems and Applications in Engineering, vol. 12, no. 3, 2024. [En línea]. Disponible en: <https://ijisae.org/index.php/IJISAE/article/view/5226>