


Decodificando la Oferta Productiva del Aguacate

Evaluación de Modelos Predictivos y Estrategias de Ensamble para la Toma de Decisiones

Equipo 29 - Proyecto Integrador



El Desafío: Comportamiento del Aguacate



Objetivo: Minimizar el error en la predicción de volumen mensual para mejorar la planificación logística.

Rigor Metodológico: Validación Temporal Estricta




Validación 'Time Series Split':

Se respeta el flujo del tiempo para evitar fuga de información (data leakage) y simular un escenario real.

Orden Cronológico Estricto


El Espectro de Modelado: 7 Enfoques Evaluados




Enfoques Estadísticos: La Importancia de la Estacionalidad

ARIMA: Subestima los picos de producción ($MASE > 1.0$).


SARIMAX: Captura robustamente la estacionalidad y variables exógenas.



Deep Learning: Cuando la Complejidad $\neq$ Precisión




Desfase (Lag): El modelo no logra generalizar correctamente.



Conclusión: Modelos complejos requieren más datos históricos. La complejidad arquitectónica no garantizó mejor desempeño ($MASE > 1.0$).


El Ganador: Gaussian Process Regression (GPR)




MASE: 0.49
(Menor Error)

1. Precisión Superior.
2. Eficiencia en Datasets Pequeños.
3. Incertidumbre Explícita (Intervalos de Confianza).

Ranking Global de Desempeño (Avance 4)




Comparativa Visual: Top 2 vs. Realidad



Comportamientos complementarios ideales para estrategias de ensamble.

Evolución: Hacia Modelos de Ensemble



Objetivo: Combinar fortalezas individuales para reducir la varianza y superar el MASE de 0.49.

Estrategias de Ensamble en Implementación



Promedio Simple

Suavizado básico de errores entre modelos.



Promedio Ponderado

Asignación de mayor peso a GPR y SARIMAX.



Stacking (Ridge)


Meta-modelo lineal para combinar predicciones.



Stacking (Random Forest)

Meta-modelo no lineal para capturar relaciones complejas.

Resultados Comparativos: Individuales vs. Top 3




Análisis de Ensamble

La integración busca mitigar los errores específicos donde un modelo falla pero los otros aciertan.

Análisis Crítico: Lecciones del Modelado



Calidad > Complejidad:
GPR superó a redes profundas (LSTM).



Valor de la Incertidumbre:
Los modelos probabilísticos son vitales para la gestión de riesgos.




Sin “Bala de Plata”: La combinación de modelos temporales y no temporales es necesaria.



Estabilidad: Ausencia de sobreajuste (overfitting) significativo en los modelos líderes.


Conclusiones y Recomendación Final

Acción Inmediata



Implementar GPR (Gaussian Process Regression). Ofrece el menor error (MASE 0.49) y rangos de incertidumbre para decisiones logísticas seguras.

Siguiente Frontera



Finalizar ajuste de Stacking Ensembles. Capturar la robustez de SARIMAX junto a la flexibilidad de GPR.

Impacto: Reducción del error de pronóstico en ~50% respecto a la línea base.